

به نام خدا



دانشگاه تهران
دانشکده فنی
دانشکده مهندسی برق و
کامپیوتر



درس بازیابی هوشمند اطلاعات

پاسخ بخش تئوری تمرین ۱

نام و نام خانودگی: عرفان شهابی

مهر ماه ۱۴۰۳

4	پاسخ سوال اول
4	پاسخ بخش اول
10	پاسخ بخش دوم
12	پاسخ بخش سوم
13	پاسخ سوال دوم
13	پاسخ بخش اول
16	پاسخ بخش دوم
16	پاسخ بخش سوم
18	مدل پیشنهادی در کد

پاسخ سوال اول

پاسخ بخش اول

کلمات کلیدی: ماشین، یادگیری، الگوریتم ها، عمیق، عصبی، شبکه، داده، کاوی، آماری، روشها، پیشرفته، کامپیوتر، علم

جدول 1

سند	محتوای سند	تعداد کل کلمات	کلمات کلیدی موجود	تعداد کل کلمات کلیدی
D1	مقدمه ای بر یادگیری ماشین	۵	یادگیری، ماشین	۲
D2	یادگیری عمیق و شبکه های عصبی	۶	یادگیری، عمیق، شبکه، عصبی	۴
D3	الگوریتم ها برای داده کاوی	۴	الگوریتم ها، داده، کاوی	۳
D4	الگوریتم های یادگیری ماشین در پایتون	۵	الگوریتم ها، یادگیری، ماشین	۳
D5	روش های آماری در یادگیری ماشین	۵	روش ها، آماری، یادگیری، ماشین	۴
D6	الگوریتم های پیشرفته در علوم کامپیوتر	۵	الگوریتم، پیشرفته، کامپیوتر	۳

کلمه	D1	D2	D3	D4	D5	D6	QUERY
ماشین	1	0	0	1	1	0	1
یادگیری	1	1	0	1	1	۰	1
الگوریتم ها	0	0	1	1	0	0	1
عمیق	0	1	0	0	0	0	0
عصبی	0	1	0	0	0	0	0
شبکه	0	1	0	0	0	0	0
داده	0	0	1	0	0	0	0
کاوی	0	0	1	0	0	0	0
روش ها	0	0	0	0	1	۰	0
آماري	0	0	0	0	1	۰	0
پیشرفته	0	0	0	0	0	۱	0
کامپیوتر	0	0	0	0	0	۱	0
علم	0	0	0	0	0	1	0

تعداد تکرار کلمات در هر سند

به دست آوردن مقدار IDF

idf		کلمه
Log(6/4)	0.176	ماشین
Log(6/4)	0.176	یادگیری
Log(6/2)	0.477	الگوریتم ها
Log(6/1)	0.778	عمیق
Log(6/1)	0.778	عصبی
Log(6/1)	0.778	داده
Log(6/1)	0.778	کاوی
Log(6/1)	0.778	روش ها
Log(6/1)	0.778	آماري
Log(6/1)	0.778	پیشرفته
Log(6/1)	0.778	کامپیوتر
Log(6/1)	0.778	علم

به دست آوردن مقدار TF-IDF

کلمه	TF-IDF(D1)	TF-IDF(D2)	TF-IDF(D3)	TF-IDF(D4)	TF-IDF(D5)	TF-IDF(D6)	QUERY
ماشین	0.176	0	0	0.176	0.176	0	0.176
یادگیری	0.176	0.176	0	0.176	0.176	۰	0.176
الگوریتم ها	0	0	0.477	0.477	0	0	0.477
عمیق	0	0.778	0	0	0	0	0
عصبی	0	0.778	0	0	0	0	0
شبکه	۰	0.778	۰	۰	۰	۰	۰
داده	0	0	0.778	0	0	0	0
کاوی	0	0	0.778	0	0	0	0
روش ها	0	0	0	0	0.778	۰	0
آماري	0	0	0	0	0.778	۰	0
پیشرفته	0	0	0	0	0	0.778	0
کامپیوتر	0	0	0	0	0	0.778	0
علم	0	0	0	0	0	0.778	0

بردارها:

$$Q = [0.477, 0.176, 0.176]$$

$$D1 = [0, 0.176, 0.176]$$

$$D2 = [0, 0.176, 0]$$

$$D3 = [0.477, 0, 0]$$

$$D4 = [0.477, 0.176, 0.176]$$

$$D5 = [0, 0.176, 0.176]$$

$$D6 = [0.477, 0, 0]$$

شباهت کسینوسی بین پرس و جو و هر سند:

$$\text{Cosine Similarity}(A,B) = \frac{A.B}{||A|| ||B||}$$

$$|Q| = \sqrt{0.477^2 + 0.176^2 + 0.176^2} = 0.538$$

$$|D1| = \sqrt{0^2 + 0.176^2 + 0.176^2} = 0.249$$

$$|D2| = \sqrt{0^2 + 0.176^2 + 0^2} = 0.176$$

$$|D3| = \sqrt{0.477^2 + 0^2 + 0^2} = 0.477$$

$$|D4| = \sqrt{0.477^2 + 0.176^2 + 0.176^2} = 0.538$$

$$|D5| = \sqrt{0^2 + 0.176^2 + 0.176^2} = 0.249$$

$$|D6| = \sqrt{0.477^2 + 0^2 + 0^2} = 0.477$$

$$Q \cdot D1 = (0.477 \times 0) + (0.176 \times 0.176) + (0.176 \times 0.176) = 0.062$$

$$Q \cdot D2 = (0.477 \times 0) + (0.176 \times 0.176) + (0.176 \times 0) = 0.031$$

$$Q \cdot D3 = (0.477 \times 0.477) + (0.176 \times 0) + (0.176 \times 0) = 0.228$$

$$Q \cdot D4 = (0.477 \times 0.477) + (0.176 \times 0.176) + (0.176 \times 0.176) = 0.289$$

$$Q \cdot D5 = (0.477 \times 0) + (0.176 \times 0.176) + (0.176 \times 0.176) = 0.062$$

$$Q \cdot D6 = (0.477 \times 0.477) + (0.176 \times 0) + (0.176 \times 0) = 0.228$$

$$\text{Cosine Similarity}(Q, D1) = \frac{0.062}{0.538 \times 0.249} = 0.463$$

$$\text{Cosine Similarity}(Q, D2) = \frac{0.031}{0.538 \times 0.176} = 0.327$$

$$\text{Cosine Similarity}(Q, D3) = \frac{0.228}{0.538 \times 0.477} = 0.888$$

$$\text{Cosine Similarity}(Q, D4) = \frac{0.289}{0.538 \times 0.538} = 0.998$$

$$\text{Cosine Similarity}(Q, D5) = \frac{0.062}{0.538 \times 0.249} = 0.463$$

$$\text{Cosine Similarity}(Q, D6) = \frac{0.228}{0.538 \times 0.477} = 0.888$$

رتبه بندی بر اساس شباهت کسینوسی:

رتبه	سند
۱	D4
۲	D3, D6
۳	D1, D5
۴	D2
۵	
۶	

اجرای روش بازخورد Rocchio

$$\begin{aligned}
 \mathbf{qm} &= \alpha \mathbf{q0} + \beta \left(\frac{1}{|Dr|} \sum_{dj \in Dr} dj \right) - \gamma \left(\frac{1}{|Dnr|} \sum_{dj \in Dnr} dj \right) \\
 \mathbf{qm} &= 1 \times [0.477, 0.176, 0.176] + 0.75 \left(\frac{1}{0.477} \sum_{dj \in Dr} [0.477, 0, 0] \right) - 0.25 \left(\frac{1}{0.176} \sum_{dj \in Dnr} [0, 0.176, 0] \right) \\
 \mathbf{qm} &= 1[0.477, 0.176, 0.176] + [0.75, 0, 0] + [0, 0.25, 0] \\
 \mathbf{qm} &= [1.277, 0.426, 0.176]
 \end{aligned}$$

شباهت کسینوسی بین پرس و جو تنظیم شده $\mathbf{qm}$ و هر سند:

$$\begin{aligned}
 |\mathbf{Qm}| &= \sqrt{1.277^2 + 0.426^2 + 0.176^2} = 1.358 \\
 \mathbf{Qm} \cdot \mathbf{D1} &= (1.277 \times 0) + (0.426 \times 0.176) + (0.176 \times 0.176) = 0.106 \\
 \mathbf{Qm} \cdot \mathbf{D2} &= (1.277 \times 0) + (0.426 \times 0.176) + (0.176 \times 0) = 0.075 \\
 \mathbf{Qm} \cdot \mathbf{D3} &= (1.277 \times 0.477) + (0.426 \times 0) + (0.176 \times 0) = 0.609 \\
 \mathbf{Qm} \cdot \mathbf{D4} &= (1.277 \times 0.477) + (0.426 \times 0.176) + (0.176 \times 0.176) = 0.715 \\
 \mathbf{Qm} \cdot \mathbf{D5} &= (1.277 \times 0) + (0.426 \times 0.176) + (0.176 \times 0.176) = 0.106 \\
 \mathbf{Qm} \cdot \mathbf{D6} &= (1.277 \times 0.477) + (0.426 \times 0) + (0.176 \times 0) = 0.609 \\
 \text{Cosine Similarity}(\mathbf{Qm}, \mathbf{D1}) &= \frac{0.106}{1.358 \times 0.249} = 0.313 \\
 \text{Cosine Similarity}(\mathbf{Qm}, \mathbf{D2}) &= \frac{0.075}{1.358 \times 0.176} = 0.312 \\
 \text{Cosine Similarity}(\mathbf{Qm}, \mathbf{D3}) &= \frac{0.609}{1.358 \times 0.477} = 0.940 \\
 \text{Cosine Similarity}(\mathbf{Qm}, \mathbf{D4}) &= \frac{0.715}{1.358 \times 0.538} = 0.979 \\
 \text{Cosine Similarity}(\mathbf{Qm}, \mathbf{D5}) &= \frac{0.106}{1.358 \times 0.249} = 0.313 \\
 \text{Cosine Similarity}(\mathbf{Qm}, \mathbf{D6}) &= \frac{0.609}{1.358 \times 0.477} = 0.940
 \end{aligned}$$

رتبه بندی بر اساس شباهت کسینوسی بین پرس و جو تنظیم شده qm و هر سند:

رتبه	سند
۱	D4
۲	D3, D6
۳	D1, D5
۴	D2
۵	
۶	

پاسخ بخش سوم

الف) مقایسه رتبه بندی TF-IDF و Rocchio:

در دو روش سند D4 بالاترین رتبه را دارد چرا که بیشترین شباهت را با کلمات استفاده شده در کویری دارد. سندهای D3 و D6 نیز در دو روش در رتبه دوم قرار گرفته اند. مقدار شباهت کسینوسی در روش Rocchio برای سند D3 افزایش پیدا کرده که به دلیل این روش است. همچنین در این روش این معیار برای سند D6 نیز افزایش پیدا کرده و با سند D3 برابر شده است که به دلیل تعداد برابر کلمات کلیدی این دو روش است و به همین علت سندهای D4 و D5 در رتبه سوم قرار گرفته اند. سند D2 نیز نا مرتبط ترین سند است و بعد از روش Rocchio مقدار شباهت کسینوسی آن کاهش پیدا کرده است.

ب)

در بازیابی برداری، هر پرس و جو به صورت یک بردار نمایش داده می شود. این بردار با استفاده از وزن های اصطلاحی که از روش هایی مانند TF-IDF به دست می آیند، ساخته می شود. پس از ارائه نتایج جستجو، کاربر می تواند اسناد مرتبط و غیرمرتبط را علامت گذاری کند. این بازخورد به سیستم کمک می کند تا بهتر بفهمد کاربر دقیقاً به چه چیزی علاقه مند است. با این اصلاح، بردار پرس و جو به گونه ای تغییر می کند که به سمت اسناد مرتبط حرکت کند و از اسناد غیرمرتبط فاصله بگیرد. این بهبود در بردار پرس و جو باعث می شود که اسناد مرتبط در رتبه بندی بالاتر قرار گیرند و اسناد غیرمرتبط پایین تر بیایند. ج) بعد از استفاده از روش Rocchio تغییری در رتبه بندی دیده نمی شود چرا که سند D4 مرتبط ترین سند با کویری کاربر بوده است و بازخورد کاربر تاثیری بر رتبه این سند نداشته. همچنین سندهای D3 و D6 به دلیل دارا بودن بردارهای مشابه با این که بعد از این روش مقدار شباهت کسینوسی آن ها افزایش یافته، اما همچنان با هم برابر و در رتبه ۲ قرار گرفته اند. سند D2 نیز در روش TF-IDF در آخرین رتبه قرار داشت و بعد از روش Rocchio چون نا مرتبط ترین روش بود رتبه اش تغییری نکرد اما میزان شباهت کسینوسی آن کاهش یافت.

پاسخ سوال دوم

پاسخ بخش اول

فرمول معیارهای درخواست شده:

تعداد کل اسناد بازیابی شده / تعداد اسناد مرتبط بازیابی شده = (P) دقت

تعداد کل اسناد مرتبط / تعداد اسناد مرتبط بازیابی شده = (R) فراخوانی

5 / تعداد اسناد مرتبط بازیابی شده در ۵ نتیجه اول = P@5

تعداد کل اسناد مرتبط / تعداد اسناد مرتبط بازیابی شده در ۵ نتیجه اول = R@5

$$MAP = \frac{\sum_{q=1}^Q AveP(q)}{Q}$$

PRECISION - R = تعداد سند م

موتور جست و جوی اول:

نتایج موتور A

رتبه	سند	مرتبط بودن
1	D1	مرتبط
2	D2	مرتبط
3	D3	مرتبط
4	D4	مرتبط
5	D9	غیرمرتبط
6	D5	مرتبط
7	D10	غیرمرتبط

$$P = \frac{5}{7} = 0.714$$

$$R = \frac{5}{8} = 0.635$$

$$P@5 = \frac{4}{5} = 0.8$$

$$R@5 = \frac{4}{8} = 0.5$$

$$MAP = \frac{\frac{1}{1} + \frac{2}{2} + \frac{3}{3} + \frac{4}{4} + \frac{5}{6}}{5} = 0.966$$

$$R\text{-precision} = \frac{4}{5} = 0.8$$

نتایج موتور B

رتبه	سند	مرتبط بودن
1	D9	غیرمرتبط
2	D10	غیرمرتبط
3	D11	غیرمرتبط
4	D12	غیرمرتبط
5	D1	مرتبط
6	D14	غیرمرتبط
7	D15	غیرمرتبط
8	D13	غیرمرتبط

$$P = \frac{8}{15} = 0.533$$

$$R = \frac{8}{8} = 1$$

$$P@5 = \frac{1}{5} = 0.2$$

$$R@5 = \frac{1}{15} = 0.066$$

$$MAP = \frac{\frac{1}{5} + \frac{2}{9} + \frac{3}{10} + \frac{4}{11} + \frac{5}{12} + \frac{6}{13} + \frac{7}{14} + \frac{8}{15}}{8} = 0.412$$

$$R\text{-precision} = \frac{1}{8} = 0.125$$

9	D2	مرتبط
10	D3	مرتبط
11	D4	مرتبط
12	D5	مرتبط
13	D6	مرتبط
14	D7	مرتبط
15	D8	مرتبط

نتایج موتور C

رتبه	سند	مرتبط بودن
1	D1	مرتبط
2	D9	غیرمرتبط
3	D2	مرتبط
4	D10	غیرمرتبط
5	D3	مرتبط
6	D11	غیرمرتبط
7	D4	مرتبط
8	D12	غیرمرتبط
9	D5	مرتبط
10	D6	مرتبط

$$P = \frac{6}{10} = 0.6$$

$$R = \frac{6}{8} = 0.75$$

$$P@5 = \frac{3}{5} = 0.6$$

$$R@5 = \frac{3}{15} = 0.2$$

$$MAP = \frac{\frac{1}{1} + \frac{2}{3} + \frac{3}{5} + \frac{4}{7} + \frac{5}{9} + \frac{6}{10}}{6} = 0.666$$

$$R\text{-precision} = \frac{3}{6} = 0.5$$

پاسخ بخش دوم

موتور جست و جو	Precision	Recall	P@5	R@5	MAP	R-Precision
A	0.714	0.635	0.8	0.5	0.966	0.8
B	0.533	1	0.2	0.066	0.412	0.125
C	0.6	0.75	0.6	0.2	0.666	0.5
بهترین موتور	A	B	A	A	A	A

پاسخ بخش سوم

موتور جست و جوی A دارای مقدار Precision خوبی است و از ۷ سندی که استخراج کرده، ۵ سند مرتبط هستند. همچنین مقدار Recall این موتور برابر 0.635 است به بدان معناست که از ۸ سند مرتبط قادر به استخراج ۵ سند بوده است. مقدار P@5 این موتور برابر 0.8 بوده که یعنی از ۵ سند اول منتشر شده، ۴ سند مرتبط بوده اند. مقدار R@5 این موتور برابر 0.5 بوده است که بدان معناست نیمی از اسناد مرتبط در ۵ سند اول منتشر شده توسط این موتور جستجو است. معیار MAP برای این موتور برابر 0.966 بوده که عدد بسیار بالایی است و نشان می دهد اسناد مرتبط در این سند به عنوان خروجی های بالا منتشر شده اند. همچنین معیار R-Precision این موتور برابر 0.8 بوده و نشان دهنده این موضوع است که در بین اولین سندهای منتشر شده فقط ۱ سند نا مرتبط است. موتور جست و جوی A در کل موتور خوبی است و برای پرس و جوهایی که هدف آن نمایش اسناد مرتبط برای کاربر با کمترین اتلاف وقت و نمایش اسناد مرتبط به عنوان اولین سندها مناسب است.

موتور جست و جوی B دارای مقدار Precision خوبی نیست و از ۱۵ سندی که استخراج کرده، ۸ سند مرتبط هستند ولی اسناد نامرتب زیادی را استخراج کرده است. همچنین مقدار Recall این موتور برابر 1 است به بدان معناست که از ۸ سند مرتبط قادر به استخراج همه اسناد بوده است. مقدار P@5 این موتور برابر 0.2 بوده که یعنی از ۵ سند اول منتشر شده، فقط ۱ سند مرتبط بوده اند. مقدار R@5 این موتور برابر 0.066 بوده است که بدان معناست فقط یک سند از اسناد مرتبط در ۵ سند اول منتشر شده توسط این موتور جستجو است. معیار MAP برای این موتور برابر 0.412 بوده و نشان می دهد اسناد مرتبط در این سند به عنوان خروجی های بالا منتشر نشده اند. همچنین معیار R-Precision این موتور برابر 0.5 بوده و نشان دهنده این موضوع است که در بین اولین سندهای منتشر شده نیمی از اسناد نا مرتبط هستند.

موتور جست و جوی B برای افرادی که نیازمند همه سند های مرتبط هستند موتور خوبی است اما اسناد نامرتب زیادی را منتشر میکند و سندهای مرتبط در رتبه های اول انتشار نیستند.

موتور جست و جوی C دارای مقدار Precision متوسطی است و از 10 سندی که استخراج کرده، 6 سند مرتبط هستند. همچنین مقدار Recall این موتور برابر 0.75 است به بدان معناست که از 8 سند مرتبط قادر به استخراج 6 سند بوده است. مقدار $P@5$ این موتور برابر 0.6 بوده که یعنی از 5 سند اول منتشر شده، 3 سند مرتبط بوده اند. مقدار $R@5$ این موتور برابر 0.2 بوده است که بدان معناست یک سند از اسناد مرتبط در 5 سند اول منتشر شده توسط این موتور جستجو است. معیار MAP برای این موتور برابر 0.666 بوده که نشان می دهد اسناد مرتبط در این سند به عنوان خروجی های بالا منتشر نشده اند و اسناد نامرتب هم در خروجی های اول هستند. همچنین معیار R-Precision این موتور برابر 0.5 بوده و نشان دهنده این موضوع است که در بین اولین سندهای منتشر شده نیمی از آن ها نامرتب است. موتور جست و جوی B از لحاظ نمایش اسناد مرتبط موتور خوبی است و برای پرس و جوهایی که هدف آن نمایش اسناد مرتبط برای کاربر میباشد مفید است و اما اسناد نامرتب زیادی را منتشر کرده که به در کاربر نمیخورد.

$$f(q, d) = \sum_{w \in q \cap d} \text{IDF}(w) \times C(w, d) \times \left(\frac{df}{M}\right)^\alpha$$

آلفا یک پارامتر تنظیم برای کنترل تاثیر وزن دهی است.