

به نام خدا



دانشگاه تهران

دانشکده فنی

دانشکده مهندسی برق و

کامپیوتر



درس بازیابی هوشمند اطلاعات

پاسخ بخش تئوری تمرین 2

نام و نام خانودگی: عرفان شهابی

آبان ماه ۱۴۰۳

3..... پاسخ سوال اول

3..... پاسخ بخش اول

3..... پاسخ بخش دوم

4..... پاسخ سوال دوم

4..... پاسخ بخش اول

4..... پاسخ بخش دوم

5..... پاسخ سوال سوم

5..... پاسخ بخش اول

5..... پاسخ بخش دوم

پاسخ سوال اول

پاسخ بخش اول

D4 = الگوریتم های یادگیری ماشین در عمل

DRICHLET PRIOR:

$$\frac{|d|}{|d| + \mu} + \frac{C(w, d)}{|d|} + \frac{\mu}{|d| + \mu} P(w|REF)$$

|d| for D4: 6

C(w,d) for D4: 1

P(w|REF): 0.002

$$P(w|d) = \frac{6}{6 + 1500} + \frac{1}{6} + \frac{1500}{6 + 1500} 0.002 = 0.173$$

پاسخ بخش دوم

طول سند می تواند تاثیر زیادی بر محاسبه احتمال کلمات داشته باشد. اسناد کوتاه ممکن است اطلاعات کافی برای برآورد دقیق احتمال کلمات نداشته باشند و احتمال کلماتی که در اسناد کوتاه کمتر تکرار می شوند، ممکن است بسیار پایین تخمین زده شود. برعکس، در اسناد بلند احتمال کلماتی که بیشتر تکرار می شوند، ممکن است بیش از حد برآورد شود. بنابراین، هموارسازی drichlet با استفاده از پارامتر μ این تفاوت ها را تنظیم می کند.

اگر مقدار μ بزرگ باشد مثلاً ۵۰۰۰، مدل بیشتر به سمت احتمال کلمات در مدل رفرنس گرایش پیدا می کند و احتمال کلمات کمتر تحت تاثیر تعداد واقعی کلمات در سند قرار می گیرد. این امر برای اسناد کوتاه تر مناسب است، زیرا مدل از اطلاعات مدل رفرنس برای پر کردن کمبود اطلاعات در سند کوتاه استفاده می کند.

پاسخ سوال دوم

پاسخ بخش اول

$$P(w|D) = (1 - \lambda) \frac{C(w, D) + \mu P(w|C)}{|D|} + \lambda \frac{C(w, D)}{|D|}$$

$$P(w|C) = 0.004$$

$$\lambda = 0.7$$

$$\mu = 1500$$

$$P(w|D) = (1 - 0.7) \frac{1 + 1500 \times 0.004}{5} + 0.7 \frac{1}{5} = 0.56$$

پاسخ بخش دوم

ترکیب دو مدل Dirichlet smoothing و jm می‌تواند به بهبود دقت سیستم بازیابی اطلاعات کمک کند، زیرا هرکدام از این مدل‌ها ویژگی‌های خاصی دارند که در موقعیت‌های مختلف می‌توانند مکمل یکدیگر باشند. مدل هموار سازی Dirichlet به اسناد بلندتر وزن بیشتری می‌دهد، چون احتمال بروز کلمات در اسناد طولانی‌تر به صورت طبیعی بیشتر است. Dirichlet زمانی بهتر عمل می‌کند که اسناد موجود در مجموعه، تنوع طولی بالایی دارند. این مدل برای کلمات کم تکرار در اسناد کوتاه‌تر، از مدل رفرنس استفاده می‌کند تا از مشکل صفر شدن احتمال جلوگیری کند. مدل هموار سازی jm به کمک ترکیب احتمالات به صورت خطی بین سند و مدل رفرنس عمل می‌کند و یک وزن ثابت برای احتمال رفرنس در نظر می‌گیرد. Jm برای مواقعی که بخواهیم تعادل بین اطلاعات سند و اطلاعات کلی رفرنس را به طور خطی تر حفظ کنیم مناسب است.

ترکیب این دو مدل، به این دلیل کارآمد است که نقاط قوت هر کدام را تقویت می‌کند و نقاط ضعفشان را کاهش می‌دهد. مد هموارسازی Dirichlet معمولاً برای اسناد بلندتر بهتر عمل می‌کند و jm به دلیل ثابت بودن وزن، تعادلی را برای تمامی اسناد ایجاد می‌کند. ترکیب این دو مدل می‌تواند به سیستمی منجر شود که هم برای اسناد کوتاه و هم برای اسناد بلند عملکرد بهینه‌تری داشته باشد.

پاسخ سوال سوم

پاسخ بخش اول

در سیستم بازخورد شبه مرتبط، از اسنادی که در جستجوی اولیه به عنوان مرتبط بازیابی شده اند، برای اصلاح و بهبود کوئری اولیه استفاده می شود. این اصلاح کوئری به روشی است که با تحلیل محتوای این اسناد، کلمات و عبارات مهم و مرتبط، استخراج شده و در کوئری اصلاح شده اضافه میشوند تا دقت جستجو افزایش یابد. در ابتدا، کلمات پرتکرار و مهم از هر سند استخراج می شوند. برای این کار می توان از تکنیک هایی مانند TF-IDF استفاده کرد تا مشخص شود کدام کلمات در این اسناد خاص مهم تر هستند. سپس کلمات وزن دهی شده، و کوئری جدید با استفاده از کلمات جدید استخراج شده و وزن آن ها تغییر می یابد.

پاسخ بخش دوم

این عدم ارتباط سند D3 می تواند اثرات منفی بر اصلاح پرسش و نتایج جستجو داشته باشد، زیرا کلمات موجود در سند D3 می توانند به پرسش جدید اضافه شوند و منجر به بازیابی اسناد نامرتب شوند. برای حل این مشکل برای مثال می توان از روش شباهت کسینوسی استفاده کرد تا مطمئن شویم اسنادی که به عنوان مرتبط انتخاب می شوند، واقعاً شباهت معنایی با کوئری اصلی را دارند. اگر سندی شباهت کافی نداشته باشد، می توان آن را از فرآیند اصلاح کوئری حذف کرد. و یا می توان در فرآیند استخراج کلمات کلیدی از اسناد، ترشلهدی تعریف کرد که تنها کلماتی که وزن آن ها به حد مشخصی می رسد در اصلاح کوئری لحاظ شوند. این روش باعث می شود که کلمات نامرتب با وزن کم تر وارد کوئری جدید نشوند و دقت نتایج بهبود یابد.