

به نام خدا



دانشگاه تهران
دانشکده فنی
دانشکده مهندسی برق و کامپیوتر



درس بازیابی هوشمند اطلاعات

تمرین ۲

استاد درس: خانم دکتر آزاده شاکری

سرپرست دستیاران آموزشی: سمانه پیمانی‌راد

طراح تمرین: امیرحسین روشن دل

آبان ماه ۱۴۰۳

۳.....	مقدمه
۵.....	سوالات عملی (۶۵ نمره)
۶.....	مجموعه داده
۸.....	پیش‌نیازها – ایجاد شاخص
۹.....	سوال ۱: هموارسازی (۴۵ نمره)
۱۱.....	سوال ۲: پیاده سازی تابع وزن دهی با استفاده از Pseudo Relevance Feedback (۲۰ نمره)
۱۳.....	سوالات تئوری (۳۵ نمره)
۱۴.....	سوال ۱: هموارسازی DIRICHLET (۱۰ نمره)
۱۵.....	سوال ۲: طراحی مدل ترکیبی برای بهبود دقت بازیابی (۱۰ نمره)
۱۶.....	سوال ۳: بازخورد شبه مرتبط با یک سیستم بازیابی پویا (۱۵ نمره)
۱۷.....	ملاحظات (حتما مطالعه شود)

با توجه به افزایش روزافزون حجم اطلاعات و تنوع بالای روش‌های بازیابی اطلاعات، استفاده از تکنیک‌های پیشرفته در این زمینه اهمیت فراوانی پیدا کرده است. این تکنیک‌ها به منظور بهبود کیفیت و دقت دسترسی به اطلاعات به کار می‌روند و نقش مهمی در بهینه‌سازی نتایج جستجو دارند. یکی از مؤثرترین ابزارهایی که در فرآیند بازیابی اطلاعات مورد استفاده قرار می‌گیرد، استفاده از مدل‌های وزن‌دهی **Pseudo Relevance Feedback** است. این روش‌ها با تحلیل نتایج اولیه جستجو و تطبیق آن‌ها با معیارهای ارتباط، به رتبه‌بندی و بهبود کیفیت نتایج بازیابی کمک می‌کنند.

از طرفی، تکنیک‌های هموارسازی نیز با هدف بهبود دقت و پایداری مدل‌ها، در بهینه‌سازی فرآیند بازیابی اطلاعات نقش بسزایی ایفا می‌کنند. این روش‌ها از طریق کاهش نوسانات و بهینه‌سازی پارامترهای مدل، امکان ارائه نتایج دقیق‌تر و مرتبط‌تر را فراهم می‌سازند. به طور کلی، استفاده از این ابزارها و تکنیک‌ها منجر به بهبود کارایی سامانه‌های بازیابی اطلاعات و افزایش دقت در پاسخ‌گویی به نیازهای کاربران می‌شود.

ابزار مورد استفاده در این تمرین یک موتور جستجو و شاخص‌گذاری ساده به زبان پایتون است که توسط دستیاران آموزشی این درس به‌طور خصوصی طراحی و توسعه داده شده است تا دانشجویان امکان انجام آزمایش‌ها را داشته باشند.

اهداف تمرین:

- پیاده‌سازی تکنیک‌های هموارسازی و تابع وزن‌دهی در بازیابی اطلاعات
- انجام آزمایش‌ها و ارزیابی عملکرد روش‌ها بر روی مجموعه داده‌های موجود
- مقایسه نتایج به‌دست‌آمده و تحلیل تأثیر هر روش بر بهبود دقت بازیابی اطلاعات

نکات قابل توجه در هنگام پاسخ به سؤالات:

- تمامی کدهای نوشته شده باید قابلیت اجرای مجدد داشته باشند. به تفسیرهایی که بدون آزمایش و صرفاً به صورت فرضی بیان گردند نمره‌ای تعلق نمی‌گیرد.
- نمره اصلی تمرین مربوط به کیفیت و درستی تفسیرهای ارائه شده است.
- بهتر است از نمودارها و کشف نمونه‌های مرتبط از اسناد و پرس‌وجوها برای افزایش کیفیت تفسیرها استفاده گردد.
- بدیهی است که حجم تمرین معیار نمره‌ی شما نیست، بلکه صحت انجام آزمایش‌ها و کیفیت تفسیرهای شما مهم است.
- توصیه می‌شود انجام تمرین را به روزهای آخر موکول نکنید! اجرای آزمایش‌ها زمان‌بر بوده و تفسیر هر کدام نیازمند تحلیل و بررسی است.
- فایل قوانین استفاده از ابزارهای مبتنی بر LLMs نظیر ChatGPT که در ایلرن آپلود شده است را به دقت مطالعه کنید.

در تمرین اول با معیارهای ارزیابی و توابع امتیازدهی به اسناد آشنا شدید دیدید که یک تابع امتیازدهی با توجه به میزان ارتباط یک سند با پرس وجو امتیازی به سند تخصیص میدهد تا در نهایت اسناد براساس، امتیازشان رتبه بندی و نمایش داده شوند. در این تمرین قصد داریم روشهای مختلف هموارسازی توابع بازتابی و Pseudo Relevance Feedback را مورد مطالعه قرار بدهیم.

پاسخ سوالات این بخش را در همان نوت‌بوک تمرین خود (*IIR-CA2-Code.ipynb*) بنویسید.

باتوجه به حجم مجموعه داده اجرای این کد به طور تقریبی حداکثر نیازمند ۶ گیگابایت رم در دسترس است. در صورتی که امکان اجرای کد روی سیستم خود را ندارید می‌توانید از Google Colab استفاده کنید (نیازی به اجرا بر روی GPU نیست و در حالت CPU می‌توانید کدهای خود را اجرا کنید). برای بارگذاری فایل دادگان در گوگل کولب می‌توانید از لینک گوگل درایو قرارداده شده در سامانه ایلرن استفاده کنید.

برای این تمرین یک مجموعه داده (در پوشه data) به ساختار زیر در اختیار شما قرار گرفته است. در ابتدای فایل تمرین خود دقت کنید آدرس فایل‌ها به درستی تنظیم شده باشد. نیازی به تغییر مراحل پردازش فایل‌ها در کد نیست و این بخش برای آشنایی شما با فایل‌ها است.

پیکره متنی^۱ (فایل اسناد):

این فایل شامل مجموعه‌ای از ۱۱۳۰۰۵ اسناد خبری است که هر سند دارای فیلدهای زیر می‌باشد:

- DOCNO شناسه هر سند.
- DOCID شناسه داخلی سند.
- SOURCE منبع خبری که سند از آن استخراج شده است.
- DATE تاریخ انتشار سند.
- SECTION بخش خبری مرتبط با سند.
- LENGTH طول سند بر حسب تعداد کلمات.
- HEADLINE تیتر یا عنوان سند.
- BYLINE اطلاعات نویسنده یا نویسندگان سند.
- TEXT متن اصلی سند که شامل چندین پاراگراف است.

فایل پرس‌وجوها^۲:

این فایل شامل مجموعه‌ای از پرس‌وجوهای خبری یا همان کوئری‌ها است.

^۱ Corpus

^۲ Queries

فایل دادگان طلایی^۳:

این فایل شامل قضاوت‌های مرتبط^۴ می‌باشد در مرحله نهایی جهت ارزیابی کارایی توابع بازیابی مورد استفاده قرار می‌گیرد.

Golden Dataset^۳
Relevance Judgments^۴

همان‌طور که در مباحث درس بازیابی هوشمند اطلاعات اشاره شد، جهت استفاده از اسناد در توابع بازیابی، ابتدا باید اسناد پردازش و شاخص‌گذاری شوند. شاخص‌گذاری به منظور دسترسی سریع‌تر به اطلاعات و آمارهای مورد نیاز برای محاسبه‌ی مقادیر امتیازها صورت می‌گیرد و یکی از مراحل کلیدی در فرآیند جستجو است.

برای شاخص‌گذاری و پردازش اسناد، نیازی به نوشتن کد جدید نیست. شما صرفاً باید کدهای موجود در فایل اصلی (فایل نوت‌بوک تمرین) را با مسیردهی درست به فایل‌های دادگان اجرا کنید. در فایل نوت‌بوک ارائه شده همراه تمرین، اجرای کدهای مربوط به شاخص‌گذاری و پردازش اسناد در ابتدای فایل قابل مشاهده است. این کدها شامل مراحل پیش‌پردازش و شاخص‌گذاری می‌باشند و نیازی به تغییرات در آن‌ها نیست. موتور جستجو و شاخص‌گذاری به کار رفته در این تمرین شامل چند فایل جداگانه است که در فایل نوت‌بوک وارد (import) شده و استفاده می‌شوند:

- document_processing.py
- evaluation.py
- inverted_index.py
- retrieval_models.py

برای انجام این تمرین نیازی به تغییر کدهای هیچ‌کدام از این فایل‌ها، به جز فایل `retrieval_models.py` نیست. در سوال ۱ و ۲ درباره‌ی اینکه چه کدهای باید به این بخش اضافه کنید توضیح داده شده است.

سوال ۱: هموارسازی (۴۵ نمره)

یکی از مشکلات حوزه بازیابی اطلاعات و روشهای Likelihood وجود احتمال های صفر برای کلماتی است که در اسناد مشاهده نمیشوند روشهای هموارسازی برای حل این مشکل مطرح شده اند تا احتمال رخداد کلمات دیده نشده پرس وجو در اسناد را تخمین بزنند.

هدف از این سوال آشنایی با روشهای هموارسازی میباشد. با استفاده از نمودار مناسب برای هر یک از روشهای خواسته شده مقادیر مختلف μ ، α ، λ و δ را بررسی کنید و مقدار بهینه را گزارش نمایید.

روشهایی که قصد داریم در این تمرین مورد بررسی قرار دهیم عبارتند از:

- روش Additive Smoothing با پارامتر δ

- روش JM با پارامتر λ

- روش Dirichlet Prior با پارامتر μ

- روش هموارسازی دو مرحله ای با پارامترهای λ و μ ^۶

$$p(w|d) = (1 - \lambda) \frac{c(w, d) + \mu p(w|C)}{|d| + \mu} + \lambda p(w|C)$$

- (امتیازی) - روش هموارساز Absolute Discounting با پارامتر δ

$$p(w|d) = \frac{\max(c(w, d) - \delta, 0) + \delta |d|_u p(w|C)}{|d|}$$

^۶ هموارسازی دو مرحله از ترکیب دو روش هموارسازی JM و Dirichlet بدست می آید.

راهنمایی:

- کد مربوط به روش BM25 در فایل retrieval_models.py پیاده‌سازی شده است و همچنین یک اجرای نمونه از آن در ابتدای فایل نوت‌بوک داده شده است. شما می‌توانید از این نمونه برای فهمیدن چگونگی انجام جستجوها و دریافت نتیجه ارزیابی‌ها استفاده کنید.
- یکی از اهداف اصلی این تمرین توانایی اجرای آزمایش‌ها به نحوی صحیح و مهندسی شده برای یافتن مقدار پارامترهای مناسب برای هر روش است. ابتدا پارامترها را با گام‌های بلند و سپس با گام‌های کوچک آزمایش‌های خود را تکمیل کنید تا منابع محاسباتی تلف نشود.
- برای نمایش تأثیر هر یک از پارامترها، نمودارهایی مناسب رسم کرده و تفسیر خود را بر اساس آن‌ها بنویسید.
- برای پیاده‌سازی روش‌های پیشنهادی، می‌توانید هر روش را به‌عنوان یک تابع جدید در ادامه فایل retrieval_models.py و با ساختاری مشابه تابع BM25 پیاده‌سازی کنید. همچنین با مطالعه‌ی تابع BM25، متوجه بخش‌های مختلف مورد نیاز برای پیاده‌سازی دیگر روش‌ها خواهید شد. دقت داشته باشید که نیازی به تغییر تنظیمات import در ابتدای نوت‌بوک نیست. پس از تغییر و ذخیره فایل، می‌توانید از آن بدون import مجدد استفاده کنید.
- معیارهای ارزیابی **P@5**، **nDCG@5**، **MAP**، **Recall@10** می‌باشند.

سوال ۲: پیاده سازی تابع وزن دهی با استفاده از PRF (۲۰ نمره)

در این سوال، شما باید بخشی از الگوریتم Pseudo Relevance Feedback (PRF) را با استفاده از Mixture Models پیاده سازی کنید. شما باید بخش مربوط به مراحل E-step و M-step در الگوریتم EM را تکمیل کنید. بقیه قسمت‌ها برای شما آماده شده‌اند.

شرح وظایف:

کد ارائه شده در انتهای فایل retrieval_models.py با نام (mixture_model_prf)، شامل تمامی مراحل برای انجام PRF با استفاده از Mixture Models است، به جز قسمت‌هایی که شما باید آنها را پیاده سازی کنید. این قسمت‌ها شامل موارد زیر می‌باشند:

گام ۱: پیاده سازی E-step

در این مرحله شما باید احتمال $p(z_i=1|w_i)$ را برای هر واژه محاسبه کنید.

- در ابتدا، مقدار صورت کسر (احتمال واژه در اسناد مرتبط) را محاسبه کنید.
- سپس، مخرج کسر (مجموع احتمال واژه در اسناد مرتبط و احتمال پس زمینه) را محاسبه کرده و نسبت را تعیین کنید.

گام ۲: پیاده سازی M-step

در این مرحله شما باید:

- احتمال $P(w_i|\theta_f)$ را به روز رسانی کنید. این مقدار باید با توجه به $p(z_i=1|w_i)$ و فرکانس واژه‌ها در اسناد منتخب محاسبه شود.

- مقدار λ را نیز به روزرسانی کنید. λ نشان‌دهنده تعادل بین اسناد مرتبط و مدل پس‌زمینه است و باید با توجه به $p(z_i=1|w_i)$ محاسبه شود.

الف) با استفاده از نمودار مناسب رابطه بین تعداد سندهای منتخب برای بازخورد به ازای مقادیر بزرگتر از ۱ و معیارهای ارزیابی را نمایش دهید و سپس به تحلیل نتایج پردازید در نهایت مقدار بهینه را شناسایی و گزارش کنید.

ب) با توجه به تعداد اسناد منتخب رابطه بین تعداد کلمات استخراج شده برای بازخورد و معیار ارزیابی را با نمودار مناسب نمایش دهید مقدار بهینه را گزارش کرده و در نهایت به تحلیل نتایج به دست آمده پردازید.

سوالات تئوری (۳۵ نمره)

باتوجه به مباحث تدریس شده سوالات زیر را حل کنید. پاسخ سوالات این بخش باید در قالب مربوط به

سوالات تئوری (IIR-CA2-Theory) بنویسید.

نکات سوالات تئوری:

- صرفاً به جواب نهایی نمره تعلق نمی‌گیرد و راه‌حل نوشته شده بخش اصلی نمره‌ی شماست.
- می‌توانید جهت اطمینان از محاسبات خود از کدنویسی استفاده کنید، اما باید راه‌حل به طور کلی به صورت ریاضی در گزارش تمرین آمده باشد و صرفاً قراردادن کد راه‌حل باعث کسر نمره شما می‌شود.

سوال ۱: هموارسازی DIRICHLET (۱۰ نمره)

فرض کنید از مدل هموارسازی Dirichlet برای محاسبه احتمال کلمات در سیستم بازیابی اطلاعات استفاده می‌کنید. اطلاعات هر داکيومنت در جدول بالا آمده است. احتمال کلمه "یادگیری" در کل پیکره برابر با ۰,۰۰۲ است.

شماره سند	محتوای سند
D1	الگوریتم‌های پایه‌ای برای یادگیری ماشین
D2	شبکه‌های عصبی و یادگیری عمیق
D3	داده‌کاوی و الگوریتم‌های پیشرفته
D4	الگوریتم‌های یادگیری ماشین در عمل
D5	روش‌های آماری و یادگیری ماشین
D6	پیشرفت‌های جدید در الگوریتم‌های علوم کامپیوتر

۱. با استفاده از هموارسازی Dirichlet و $\mu=1500$ ، احتمال کلمه "یادگیری" را در داکيومنت D4

محاسبه کنید. طول داکيومنت و تعداد تکرار کلمه را از جدول بالا استخراج کنید.

۲. توضیح دهید که چگونه هموارسازی Dirichlet به تنظیم بهتر احتمال کلمات در اسناد با طول‌های

متفاوت کمک می‌کند و چرا طول سند در این مدل اهمیت دارد. همچنین، تحلیل کنید که اگر μ را

افزایش دهیم (به عنوان مثال به ۵۰۰۰)، چه اتفاقی می‌افتد.

سوال ۲: طراحی مدل ترکیبی برای بهبود دقت بازیابی (۱۰ نمره)

فرض کنید شما قصد دارید از ترکیب دو مدل هموارسازی (JM) و Dirichlet برای بهبود دقت سیستم خود استفاده کنید. داکيومنت‌های زیر برای این آزمایش استفاده می‌شوند:

شماره سند	محتوای سند
D1	شبکه های عصبی پایه
D2	آموزش های تخصصی شبکه عصبی
D3	شبکه های پیچیده و یادگیری ماشین

احتمال کلمه "شبکه" در کل پیکره برابر با ۰,۰۰۴ است.

۱. برای داکيومنت D2، احتمال کلمه "شبکه" را با استفاده از مدل ترکیبی زیر محاسبه کنید:

$$P(w|D) = (1 - \lambda) \frac{c(w, D) + \mu P(w|C)}{|D| + \mu} + \lambda \frac{c(w, D)}{|D|}$$

فرض کنید $\lambda=0.7$ و $\mu=1500$.

۲. توضیح دهید که چرا ترکیب این دو مدل می‌تواند دقت سیستم را بهبود بخشد و در چه مواقعی این مدل ترکیبی می‌تواند کارایی بهتری نسبت به هر یک از مدل‌ها به تنهایی داشته باشد.

سوال ۳: بازخورد شبه مرتبط با یک سیستم بازیابی پویا (۱۵ نمره)

فرض کنید شما قصد دارید از بازخورد شبه مرتبط (Pseudo Relevance Feedback) در یک سیستم بازیابی پویا استفاده کنید. پس از اجرای اولیه جستجو با عبارت "آموزش شبکه‌های عصبی"، سیستم شما سه سند D1، D2 و D3 را به عنوان مرتبط انتخاب می‌کند. این سه سند حاوی اطلاعاتی درباره "شبکه‌های عصبی"، "آموزش ماشین" و "روش‌های یادگیری" هستند.

۱. توضیح دهید که چگونه می‌توانید از اطلاعات موجود در این سه سند برای اصلاح پرسش اولیه استفاده کنید. به طور خاص، توضیح دهید که چگونه کلمات جدید و مهم از این اسناد استخراج شده و وزن‌دهی می‌شوند تا دقت جستجو افزایش یابد.

۲. فرض کنید سند D3 در واقع مرتبط نبوده و حاوی اطلاعاتی درباره "روش‌های داده‌کاوی" است. توضیح دهید که چگونه این خطا می‌تواند بر نتایج جستجو تأثیر بگذارد و چه راه‌حلی برای تشخیص اسناد نامرتبط و جلوگیری از این مشکل پیشنهاد می‌کنید.

تمامی نتایج شما باید در یک فایل فشرده با عنوان IIR-CA2-StudentID تحویل داده شود.

- خوانایی و دقت بررسی‌ها در گزارش نهایی از اهمیت ویژه‌ای برخوردار است. به تمرین‌هایی که به صورت کاغذی تحویل داده شوند یا به صورت عکس در سایت بارگذاری شوند، ترتیب اثری داده نخواهد شد. **دقت کنید که حتما گزارشات خود را در قالب ارائه شده برای تحویل تکالیف که در سامانه برای شما بارگذاری شده است ارسال بفرمایید.**
- کدهای نوشته شده برای هر بخش را با نام مناسب مشخص کرده و به همراه گزارش تکلیف ارسال کنید. همه‌ی کدهای پیوست گزارش بایستی قابلیت اجرای مجدد داشته باشند. در صورتی که برای اجرا مجدد آن‌ها نیاز به تنظیمات خاصی می‌باشد بایستی تنظیمات مورد نیاز را نیز در گزارش خود ذکر کنید. **دقت کنید که تمامی کدها باید توسط شما اجرا شده باشند و نتایج اجرا در فایل کدهای ارسالی مشخص باشد. به کدهایی که نتایج اجرای آن‌ها در فایل ارسالی مشخص نباشد نمره‌ای تعلق نمی‌گیرد.**
- تمرین تا یک هفته بعد از مهلت تعیین شده با تاخیر تحویل گرفته می‌شود. دقت کنید که شما جمعا برای تمام تکالیف، ۱۴ روز زمان تحویل بدون جریمه دارید که تنها از ۷ روز آن برای هر تمرین می‌توانید استفاده کنید، در صورتی که این ۱۴ روز به اتمام رسیده باشد، به ازای هر روز تأخیر در ارسال تمرین، ده درصد جریمه می‌شوید.
- **توجه کنید این تمرین باید به صورت تک نفره انجام شود و پاسخ‌های ارائه شده باید نتیجه فعالیت فرد نویسنده باشد (همفکری و به اتفاق هم نوشتن تمرین نیز ممنوع است). در صورت مشاهده تشابه به همه افراد مشارکت کننده، نمره ۵۰- تعلق می‌گیرد و به استاد نیز گزارش می‌گردد.**
- در صورت بروز هرگونه مشکل با ایمیل زیر در ارتباط باشید:

۱ آبان ۱۴۰۳	تاریخ آپلود تمرین
۱۴ آبان ۱۴۰۳	مهلت تحویل بدون جریمه
۲۱ آبان ۱۴۰۳	مهلت تحویل با تأخیر، با جریمه ۱۰ درصد