

به نام خدا



دانشگاه تهران

دانشکده فنی

دانشکده مهندسی برق و کامپیوتر



درس بازیابی هوشمند اطلاعات

تمرین پنجم

استاد درس: خانم دکتر آزاده شاکری

سرپرست دستیاران آموزشی: سمانه پیمانی‌راد

طراح تمرین: محمدرضا علائی

آذر ماه ۱۴۰۳

۳	مقدمه
۳	بخش اول: آشنایی با مدل زبانی BERT (۵۰ نمره)
۴	بخش ۱-۱: آشنایی با مجموعه داده‌گان
۵	بخش ۲-۱: پیش‌پردازش داده‌ها
۵	بخش ۳-۱: بارگذاری مدل BERT برای طبقه‌بندی دنباله‌ها
۵	بخش ۴-۱: تنظیم پارامترهای آموزش مدل
۶	بخش ۵-۱: آموزش مدل
۶	بخش ۶-۱: ارزیابی کارایی مدل
۷	بخش ۷-۱: سوالات پژوهشی (امتیازی)
۸	بخش دوم: طراحی یک موتور جستجو (۳۰ نمره)
۹	بخش سوم: آشنایی با مدل‌های زبانی بزرگ (۲۰ نمره)
۱۰	بخش ۱-۳: ساخت کلید دسترسی
۱۰	بخش ۲-۳: توصیف وظیفه برای مدل
۱۰	بخش ۳-۳: فراخوانی مدل
۱۰	بخش ۴-۳: ارزیابی خروجی‌ها
۱۱	ملاحظات (حتماً مطالعه شود)

مدل‌های عصبی^۱، به ویژه مدل‌های مبتنی بر ترنسفورمر مانند [BERT](#) و مدل‌های زبانی بزرگ^۲، تحولی بزرگ در زمینه بازیابی اطلاعات ایجاد کرده‌اند. این مدل‌ها، با تمرکز بر معنا و زمینه، امکان دستیابی به درک عمیق‌تری از متن را فراهم می‌سازند.

هدف از این تمرین، آشنایی با روند کار مدل‌های عصبی در بازیابی اطلاعات است. ما در این تمرین، قدم به قدم به پیاده‌سازی یک موتور جستجو خواهیم پرداخت و در مسیر آن، به درک بهتری از مدل‌های زبانی امروزی و روش کار با آن‌ها می‌رسیم. در بخش پایانی تمرین نیز با مدل‌های زبانی بزرگ آشنا شده و آن‌ها را در وظایف^۳ بازیابی اطلاعات محک خواهیم زد.

اهداف تمرین:

- آشنایی با روند تنظیم دقیق^۴ مدل‌های زبانی از پیش آموزش‌دیده
- بهره‌بردن از مدل زبانی BERT برای شناسایی ارتباط دو دنباله از کلمات
- طراحی یک موتور جستجو با کمک مدل زبانی BERT
- آشنایی با روند بازیابی اطلاعات با استفاده از مدل‌های زبانی بزرگ

نکات قابل توجه در هنگام پاسخ به سوالات:

- فایل قوانین استفاده از ابزارهای مبتنی بر LLMs نظیر ChatGPT که در elearn قرار گرفته‌است را به دقت مطالعه فرمایید.
- بدیهی‌ست که حجم تمرین معیار نمره‌ی شما نبوده و نمره‌ی اصلی تمرین، مربوط به کیفیت و درستی تفسیرهای ارائه‌شده و صحت انجام آزمایش‌ها خواهد بود. همچنین به تفسیرهایی که بدون آزمایش و صرفاً به صورت فرضی بیان گردد، نمره‌ای تعلق نمی‌گیرد.

^۱ Neural models

^۲ Large Language Models

^۳ Tasks

^۴ Fine-tune

بخش اول: آشنایی با مدل زبانی BERT (۵۰ نمره)

در بخش اول از این تمرین، یک مدل زبانی BERT را بارگذاری نموده و از خروجی‌های آن برای پیش‌بینی ارتباط دو دنباله از کلمات استفاده می‌کنیم.

بخش ۱-۱: آشنایی با مجموعه دادگان

دادگانی که برای این تمرین استفاده می‌کنیم، متشکل از ۳۳۴۶ نمونه پرس‌وجو^۵ و سند^۶، به همراه برچسب ارتباط^۷ آن‌هاست. این داده‌ها از اسناد خبری که در تمرین‌های قبلی با آن‌ها آشنا شدید استخراج شده و به فرم مناسب برای آموزش مدل‌های عصبی تبدیل شده‌اند. در پایان این بخش از تمرین، می‌توانید نتایج به‌دست‌آمده را ارزیابی کرده و آن‌ها را با نتایج روش‌های قبلی مقایسه کنید.

این دادگان را می‌توانید از فایل **dataset.csv** که در ضمیمه‌ی تمرین قرار گرفته‌است، دریافت نمایید.

برای آشنایی بیشتر با داده‌ها، آن‌ها را بارگذاری کرده و بخش‌هایی از آن را نمایش دهید. برای این کار می‌توانید از کتابخانه‌هایی مانند Datasets یا Pandas استفاده کنید.

در این دادگان، به ازای هر پرس‌وجو، تعدادی نمونه‌ی مرتبط و غیرمرتبط تعریف شده‌است. آیا توزیع برچسب‌ها در این مجموعه‌داده متعادل است؟ در صورت مشاهده‌ی عدم تعادل، استراتژی شما چه خواهد بود؟

پس از بارگذاری دادگان، آن را به سه مجموعه‌ی آموزش^۸، آزمون^۹ و اعتبارسنجی^{۱۰} تقسیم نمایید. پیشنهاد می‌شود که ۸۰ درصد از داده‌ها را برای آموزش و ۲۰ درصد باقی‌مانده را به صورت مساوی بین مجموعه‌های آزمون و اعتبارسنجی تقسیم کنید.

^۵ Query

^۶ Document

^۷ Relevance Label

^۸ Train

^۹ Test

^{۱۰} Validation

بخش ۱-۲: پیش‌پردازش داده‌ها

پس از آماده‌سازی داده‌ها، نوبت به پیش‌پردازش آن‌ها می‌رسد. در این فرایند، داده‌ها به ورودی‌های مورد انتظار مدل BERT تبدیل می‌شوند. می‌توانید برای این بخش، از ماژول **AutoTokenizer** در کتابخانه‌ی Transformers استفاده کنید. با اعمال پیش‌پردازش مناسب بر روی جفت جملات مجموعه‌داده، خروجی توکنایزر را مشاهده و بخش‌های مختلف آن را تفسیر نمایید.

یکی از مراحل پیش‌پردازش متون زبان طبیعی، حذف ایست‌واژه^{۱۱} هاست. به نظر شما، تاثیر حذف ایست‌واژه‌ها در اینجا، مثبت یا منفی خواهد بود؟ استدلال خود را بیان کنید.

بخش ۱-۳: بارگذاری مدل BERT برای طبقه‌بندی دنباله‌ها

در این بخش، یک مدل BERT پایه را برای وظیفه‌ی طبقه‌بندی دنباله‌ها بارگذاری می‌کنیم. می‌توانید برای این بخش، از ماژول **AutoModelForSequenceClassification** در کتابخانه‌ی Transformers استفاده کنید.

هدف ما، تنظیم دقیق این مدل برای یک وظیفه‌ی خاص است. برای این منظور، در فرایند آموزش، تنها لایه‌ی نهایی مدل (که وظیفه‌ی طبقه‌بندی را برعهده دارد) را آموزش می‌دهیم و سایر لایه‌ها را ثابت نگه می‌داریم. بنابراین تغییرات مورد نیاز را بر روی مدل بارگذاری شده اعمال نمایید.

بخش ۱-۴: تنظیم پارامترهای آموزش مدل

در این مرحله، پارامترهای مورد نیاز برای آموزش مدل را تنظیم می‌کنیم. از ماژول **TrainingArguments** در کتابخانه‌ی Transformers برای تعیین تنظیماتی مانند نرخ یادگیری، تعداد دوره‌های آموزش و مسیر ذخیره‌سازی مدل استفاده کنید.

اما تنها به این تنظیمات بسنده نکنید؛ در نظر داشته باشید که گزینه‌های دیگری مانند اندازه‌ی دسته‌ها^{۱۲} و زمان‌بندی نرخ یادگیری^{۱۳} نیز می‌توانند بر روند آموزش مؤثر باشند. برای آشنایی با تنظیمات پیشرفته‌تر می‌توانید به [این مستندات](#) از کتابخانه‌ی Transformers مراجعه کنید.

^{۱۱} Stop words

^{۱۲} Batch size

^{۱۳} Learning rate scheduler

سپس با استفاده از ماژول **Trainer**، فرآیند آموزش را پیکربندی نمایید. این فرایند شامل مشخص کردن دادگان آموزشی و اعتبارسنجی، معیارهای ارزیابی عملکرد مدل و دیگر تنظیمات مربوط به آموزش مدل خواهد بود.

بخش ۱-۵: آموزش مدل

مدل خود را با توجه به تنظیماتی که انجام داده‌اید و بر روی دادگان مورد نظر آموزش دهید. در طول آموزش، پیشرفت مدل را با نظارت بر معیارهایی مانند دقت، امتیاز $ROC\ AUC$ ^{۱۴} و $Loss$ ارزیابی کنید. این ارزیابی‌ها کمک می‌کنند تا مطمئن شوید مدل در حال یادگیری است.

اگر مشاهده کردید که مدل به‌درستی یاد نمی‌گیرد یا عملکرد آن بهبود نمی‌یابد، ممکن است نیاز به بازبینی تنظیمات پارامترهای مدل داشته باشید. در این صورت، به تنظیمات مانند نرخ یادگیری، اندازه‌ی دسته‌ها یا حتی تعداد دوره‌ها توجه بیشتری داشته باشید.

بخش ۱-۶: ارزیابی کارایی مدل

مدل را با استفاده از دادگان آزمون ارزیابی نمایید. برای ارزیابی عملکرد مدل، از معیارهایی مانند صحت^{۱۵}، دقت^{۱۶}، امتیاز $F1$ و فراخوانی^{۱۷} استفاده کنید تا بتوانید بهترین ارزیابی از توانایی مدل به دست آورید. با توجه به مسئله و دادگان، کدام معیار ارزیابی را برای این کار مناسب‌تر می‌دانید؟ استدلال خود را بیان کنید.

علاوه بر ارزیابی کلی مدل، پیش‌بینی‌های مدل را بر روی نمونه‌ای دلخواه از داده‌ها مشاهده کنید. خروجی پیش‌بینی مدل را به صورت یک برچسب احتمالی (بین ۰ و ۱) که نشان‌دهنده‌ی میزان ارتباط پرس‌وجو با سند است، نمایش دهید.

^{۱۴} Area under the receiver operating characteristic curve

^{۱۵} Accuracy

^{۱۶} Precision

^{۱۷} Recall

بخش ۱-۷: سوالات پژوهشی (امتیازی)

الف- همان‌طور که در بخش ۱-۲ این تمرین داشتیم، در حالت پیش‌فرض ابتدا دنباله‌ی پرس‌وجو و سپس دنباله‌ی مربوط به سند در ورودی مدل قرار می‌گیرند. به نظر شما، اگر این ترتیب معکوس شود و ابتدا سند و سپس پرس‌وجو در ورودی مدل داده شوند، چه تأثیری در خروجی مدل برای وظیفه‌ی طبقه‌بندی خواهد داشت؟ با طراحی آزمایشی، فرضیه‌ی خود را بیازمایید و تحلیل خود را بیان کنید.

ب- نقش توکن [CLS] را در مدل BERT بیان کنید. در حالتی که این توکن نتواند به اندازه‌ی کافی، رابطه‌ی بین پرس‌وجو و سند را تبیین کند، یک بازنمایی جایگزین برای این کار پیشنهاد کنید. همچنین می‌توانید از [این مقاله](#) برای رسیدن به راه‌حل ایده بگیرید.

بخش دوم: طراحی یک موتور جستجو (۳۰ نمره)

در این بخش، یک کاربرد دنیای واقعی از مدل زبانی BERT را طراحی و پیاده‌سازی می‌کنیم. با استفاده از مدلی که در بخش قبلی آموزش داده‌اید، یک موتور جستجوی اسناد خبری بسازید.

الف- این موتور جستجو را به صورتی طراحی کنید که یک پرس‌وجو و لیستی از اسناد خبری را در ورودی دریافت کرده و با بررسی احتمال ارتباط پرس‌وجو با هر کدام از اسناد، لیست مرتب‌شده‌ای از ۵ سند برتر را برگرداند.

ب- حال، موتور جستجوی خود را با یک پرس‌وجوی دلخواه و لیست اسناد دادگان آزمون فراخوانی کنید. می‌توانید برای خوانایی بهتر خروجی‌ها، تنها ۱۵۰ کاراکتر ابتدایی اسناد را در خروجی نمایش دهید.

ج- سطرهای مربوط با آن پرس‌وجو را در دادگان آزمون مشاهده کنید. آیا نمونه‌های با برچسب مرتبط، در رتبه‌بندی حضور دارند؟ آیا نمونه‌ای در رتبه‌بندی حضور دارد که در دادگان جزو نمونه‌های با برچسب مرتبط نبوده ولی در رتبه‌بندی بالاتر از آن‌ها جای گرفته‌است؟ تحلیل خود را از این موضوع بیان کنید.

(امتیازی) د- با فراخوانی موتور جستجو با پرس‌وجوهای دادگان آزمون و لیست اسناد آن دادگان، معیارهای رتبه‌بندی MAP^{18} ، $Recall@10$ ، $Precision@5$ و $nDCG^{19}@5$ را برای مدل خود بررسی نمایید. بهترین نتایج این معیارها برای روش BM25+ که در تمرین اول با آن آشنا شدید، در جدول ۱ آورده شده‌است. نتایجی که در اینجا به دست آوردید را با آن‌ها مقایسه نمایید.

جدول ۱. نتایج معیارهای ارزیابی در روش BM25+

معیار ارزیابی	بهترین نتیجه‌ی به دست آمده در روش BM25+
MAP	۰.۳۹۹۰
Recall@10	۰.۴۳۲
Precision@5	۰.۳۳۴۷
nDCG@5	۰.۵۳۳۵

¹⁸ Mean Average Precision

¹⁹ Normalized Discounted Cumulative Gain

بخش سوم: آشنایی با مدل‌های زبانی بزرگ (۲۰ نمره)

در بخش پایانی این تمرین، هدف ما پیش‌بینی احتمال ارتباط بین پرس‌وجو و سند با استفاده از مدل‌های زبانی بزرگ است. در نهایت، نتایج حاصل را با خروجی‌های مدل BERT که در بخش اول تمرین به‌دست آوردیم، مقایسه خواهیم کرد.

مدل‌های زبانی بزرگ معمولاً به منابع پردازشی بالایی نیاز دارند و بارگذاری آن‌ها به‌روش مشابه با BERT که قبلاً انجام دادیم، ممکن است امکان‌پذیر نباشد. یکی از روش‌های دسترسی به این مدل‌ها، استفاده از رابط‌های برنامه‌نویسی کاربردی (API) است. با این روش، بدون نیاز به داشتن منابع پردازشی خاص، می‌توانید از این مدل‌ها استفاده کنید.

در این بخش از تمرین، با ارسال درخواست‌های مناسب به API ارائه‌شده توسط پلتفرم [Together AI](#)، خروجی‌های مدل‌های زبانی بزرگ را استخراج خواهیم کرد.

برای آشنایی بیشتر با روند کار، یک نمونه از نحوه دسترسی به مدل و دریافت خروجی در ضمیمه‌ی تمرین قرار داده شده است. لازم به ذکر است در انتخاب نوع مدل زبانی و همچنین ابزار مورد استفاده، محدودیتی وجود ندارد.

بخش ۳-۱: ساخت کلید دسترسی

با ثبت نام در سایت Together AI، می‌توانید API key خودتان را دریافت کنید. این کلید را طبق نمونه‌ی قرار گرفته در ضمیمه‌ی تمرین، در محیط خود اضافه نمایید. ماژول‌های Together، به صورت خودکار از مقدار این متغیر^{۲۰}، برای احراز هویت شما استفاده می‌کنند.

بخش ۳-۲: توصیف وظیفه برای مدل

بخش مهمی از کار با مدل‌های زبانی بزرگ، ارائه‌ی توصیف مناسب از مسئله است. گاهی تغییرات جزئی در دستور^{۲۱}ها، تأثیر چشمگیری در کیفیت خروجی دارند. با طراحی یک دستور، وظیفه‌ی پیش‌بینی ارتباط پرس‌وجو و سند را برای مدل زبانی مورد نظر تعریف کنید. همچنین می‌توانید از روش‌های خلاقانه و پیشرفته‌تر مانند زنجیره‌ی افکار^{۲۲} و Few shot learning در توصیف وظیفه استفاده نمایید.

بخش ۳-۳: فراخوانی مدل

با استفاده از دادگان آزمون، دستورات را برای ورودی به مدل زبانی بزرگ، بسته‌بندی کنید. یک دستور، شامل توصیف وظیفه به همراه نمونه‌ی مورد نظر خواهد بود. با فراخوانی مدل، خروجی‌ها را دریافت و در یک فایل ذخیره نمایید.

بخش ۳-۴: ارزیابی خروجی‌ها

همانند بخش اول تمرین، از معیارهایی مانند صحت، دقت، امتیاز F1 و فراخوانی برای ارزیابی خروجی‌های مدل استفاده کنید. نتایج را با مدل BERT مقایسه کرده و تحلیل خود را از این مقایسه بیان کنید.

^{۲۰} TOGETHER_API_KEY

^{۲۱} Prompt

^{۲۲} Chain-of-Thought

ملاحظات (حتماً مطالعه شود)

تمامی نتایج شما باید در یک فایل فشرده با عنوان **IIR-CA5-StudentID** تحویل داده شود.

- خوانایی و دقت بررسی‌ها در گزارش نهایی از اهمیت ویژه‌ای برخوردار است. به تمرین‌هایی که به صورت کاغذی تحویل داده شوند یا به صورت عکس در سایت بارگذاری شوند، ترتیب اثری داده نخواهد شد. **دقت کنید که حتماً گزارشات خود را در قالب ارائه‌شده برای تحویل تکالیف که در سامانه برای شما بارگذاری شده است، ارسال بفرمایید.**
- کدهای نوشته شده برای هر بخش را با نام مناسب مشخص کرده و به همراه گزارش تکلیف ارسال کنید. همه‌ی کدهای پیوست گزارش بایستی قابلیت اجرای مجدد داشته باشند. در صورتی که برای اجرای مجدد آن‌ها نیاز به تنظیمات خاصی می‌باشد بایستی تنظیمات مورد نیاز را نیز در گزارش خود ذکر کنید. **دقت کنید که تمامی کدها باید توسط شما اجرا شده باشند و نتایج اجرا در فایل کدهای ارسالی مشخص باشد. به کدهایی که نتایج اجرای آن‌ها در فایل ارسالی مشخص نباشد نمره‌ای تعلق نمی‌گیرد.**
- تمرین تا یک هفته بعد از مهلت تعیین شده با تاخیر تحویل گرفته می‌شود. دقت کنید که شما جمعاً برای تمام تکالیف، ۱۴ روز زمان تحویل بدون جریمه دارید که تنها از ۷ روز آن برای هر تمرین می‌توانید استفاده کنید، در صورتی که این ۱۴ روز به اتمام رسیده باشد، به ازای هر روز تأخیر در ارسال تمرین، ۱۰ درصد جریمه می‌شوید.
- توجه کنید این تمرین باید به صورت تک نفره انجام شود و پاسخ‌های ارائه شده باید نتیجه فعالیت فرد نویسنده باشد (همفکری و به اتفاق هم نوشتن تمرین نیز ممنوع است). در صورت مشاهده تشابه به همه افراد مشارکت کننده، نمره ۵۰- تعلق می‌گیرد و به استاد نیز گزارش می‌گردد.
- در صورت بروز هرگونه مشکل می‌توانید با ایمیل زیر در ارتباط باشید:

mr.alaei@ut.ac.ir

۱۴۰۳/۰۹/۱۵	تاریخ بارگذاری تمرین
۱۴۰۳/۰۹/۳۰	مهلت تحویل بدون جریمه
۱۴۰۳/۱۰/۰۷	مهلت تحویل با تأخیر