

به نام خدا



دانشگاه تهران

دانشکده فنی

دانشکده مهندسی برق و

کامپیوتر



درس بازیابی هوشمند اطلاعات

پاسخ بخش تئوری تمرین 3

نام و نام خانودگی: عرفان شهابی

آبان ماه ۱۴۰۳

پاسخ سوال اول.....	3
پاسخ سوال دوم.....	7

پاسخ سوال اول


الف:

Dead ends: این مشکل زمانی رخ می دهد که برخی صفحات وب در گراف هیچ لینک خروجی به صفحه دیگری ندارند. در این حالت کاربر نمی تواند از این صفحه به صفحه دیگری برود و الگوریتم پیج رنک به درستی نمی تواند امتیاز این صفحات را محاسبه کند چرا که هیچ صفحه ای برای انتقال به آن وجود ندارد.

مثال:



Spider traps: این مشکل زمانی رخ می دهد که مجموعه ای از صفحه ها تنها به یکدیگر لینک دارند و هیچ پیوندی به گراف بیرونی ندارند. در این صورت هر کاربری که وارد این مجموعه از گره ها شود در این حلقه گرفتار خواهد شد و هیچگاه از این مجموعه خارج نمی شود.




در هر دو مشکل، بدون مکانیسم Random surfing، الگوریتم PageRank نمی تواند به درستی همگرا شود، زیرا:

- در Dead ends، صفحه هایی که هیچ پیوندی ندارند، باعث می شوند که امتیاز آن ها به طور نامناسب به گره های دیگر توزیع شود یا الگوریتم در آن گره ها متوقف شود.
- در Spider traps، کاربرانی که به داخل حلقه ها می روند، هیچ گاه به گراف بیرونی باز نمی گردند و امتیازها به طور تصادفی در این حلقه ها حبس می شود.

ب:

زمانی که $\alpha = 0$ باشد، الگوریتم page rank فقط به گراف اولیه و لینک های خروجی وابسته است.



با توجه به گراف داده شده ماتریس انتقال M به صورت زیر است

$$M = \begin{bmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & 0 & \frac{1}{2} \\ \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ \frac{1}{3} & \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix}$$

بردار اولیه PageRank: چون $\alpha=0$ ، بردار اولیه فقط تأثیر یکنواخت دارد:

$$PR = \begin{bmatrix} 0.25 \\ 0.25 \\ 0.25 \\ 0.25 \end{bmatrix}$$

$$PR_1 = M \cdot PR_0$$

$$PR_1 = \begin{bmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & 0 & \frac{1}{2} \\ \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ \frac{1}{3} & \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix} \begin{bmatrix} 0.25 \\ 0.25 \\ 0.25 \\ 0.25 \end{bmatrix} = \begin{bmatrix} 0.25 \\ 0.125 \\ 0.25 \\ 0.25 \end{bmatrix}$$

$$A = C = D > B$$

2

$$M' = \alpha M + (1 - \alpha) \frac{1}{N}$$

$$M' = 0.1 \begin{bmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & 0 & \frac{1}{2} \\ \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ \frac{1}{3} & \frac{1}{3} & 0 & \frac{1}{3} \end{bmatrix} + 0.9 \times \frac{1}{4}$$

$$M' = \begin{bmatrix} 0.225 & 0.275 & 0.275 & 0.225 \\ 0.225 & 0.225 & 0.225 & 0.275 \\ 0.275 & 0.225 & 0.225 & 0.275 \\ 0.258 & 0.258 & 0.225 & 0.258 \end{bmatrix}$$

$$PR_{t+1} = M'.PR_t$$

$$PR_2 = \begin{bmatrix} 0.225 & 0.275 & 0.275 & 0.225 \\ 0.225 & 0.225 & 0.225 & 0.275 \\ 0.275 & 0.225 & 0.225 & 0.275 \\ 0.258 & 0.258 & 0.225 & 0.258 \end{bmatrix} \begin{bmatrix} 0.25 \\ 0.25 \\ 0.25 \\ 0.25 \end{bmatrix} = \begin{bmatrix} 0.25 \\ 0.2375 \\ 0.25 \\ 0.249 \end{bmatrix}$$

$$PR_3 = M'.PR_2$$

$$PR_3 = \begin{bmatrix} 0.225 & 0.275 & 0.275 & 0.225 \\ 0.225 & 0.225 & 0.225 & 0.275 \\ 0.275 & 0.225 & 0.225 & 0.275 \\ 0.258 & 0.258 & 0.225 & 0.258 \end{bmatrix} \begin{bmatrix} 0.25 \\ 0.2375 \\ 0.25 \\ 0.249 \end{bmatrix} = \begin{bmatrix} 0.2463 \\ 0.235 \\ 0.247 \\ 0.2462 \end{bmatrix}$$

C>A>D>B

پاسخ سوال دوم

الف:

عملیات ضرب ماتریسی را میتوان با استفاده از الگوریتم mapreduce پیاده سازی کرد. Mapreduce الگوریتمی است که برای پردازش مجموعه داده های بزرگ به صورت توزیع شده استفاده می شود.

فرض می کنیم دو ماتریس مربعی A و B با ابعاد $n \times n$ را داریم و می خواهیم حاصل ضرب این ماتریس را حساب کنیم.

مرحله map:

در این مرحله، داده ها به صورت Key-Value نمایش داده می شوند:

هر عنصر از ماتریس A به صورت $(i, k, A[i, k])$ و هر عنصر از B به صورت $(k, j, B[k, j])$ ذخیره می شود.

Mapper برای هر ترکیب ممکن i, j, k جفت های زیر را تولید می کند:

$$((i, j), A[i, k] \times B[k, j])$$

مرحله reduce:

برای هر کلید (i, j) ، مقدار $C[i, j] = \sum (A[i, k] \times B[k, j])$ محاسبه می شود.

ب:

معماری MapReduce به دلیل توانایی در پردازش موازی داده های بزرگ می تواند برای پیاده سازی الگوریتم HITS به کار رود. الگوریتم HITS که برای تحلیل گراف لینک ها و رتبه بندی صفحات وب براساس مقادیر Authority و Hub طراحی شده است، نیازمند انجام محاسبات تکراری است که در هر مرحله مقادیر این دو پارامتر به روزرسانی می شوند.

برای پیاده سازی این الگوریتم در معماری MapReduce، مراحل الگوریتم به صورت زیر به Map و Reduce شکسته می شود:

1. مرحله: Map

- Mapper هر صفحه را با لینک های ورودی و خروجی آن پردازش می کند.
- برای محاسبه Authority، هر صفحه مقدار Hub خود را به صفحه های مقصد لینک می دهد.
- برای محاسبه Hub، هر گره مقدار Authority خود را به صفحه های مبدا لینک ارسال می کند.
- خروجی Mapper جفت های key-value به شکل (صفحه مقصد، مقدار) است.

2. مرحله: Reduce

- Reducer مقادیر ورودی را جمع می کند تا Authority و Hub جدید را برای هر گره محاسبه کند.
- در پایان، مقادیر به دست آمده نرمال سازی می شوند.