

به نام خدا



دانشگاه تهران

دانشکده فنی

دانشکده مهندسی برق و کامپیوتر



درس بازیابی هوشمند اطلاعات

تمرین ۳

استاد درس: خانم دکتر آزاده شاکری

سرپرست دستیاران آموزشی: سمانه پیمانی‌راد

طراح تمرین: علی ادیبی

آبان ماه ۱۴۰۳

۳	 مقدمه
۴	 سوالات عملی (۶۰ نمره)
۵	 مجموعه داده
۶	 سوال ۱: پیاده‌سازی الگوریتم نگاشت/کاهش (۳۰ نمره)
۷	 سوال ۲: پیاده‌سازی الگوریتم Pagerank و hits (۳۰ نمره)
۸	 سوالات تئوری (۴۰ نمره)
۹	 سوال ۱: محاسبات Pagerank (۲۵ نمره)
۱۰	 سوال ۲: نگاشت/کاهش (۱۵ نمره)
۱۱	 ملاحظات (حتما مطالعه شود)

با توجه به افزایش روزافزون حجم اطلاعات و محدود بودن زمان خواندن اطلاعات توسط یک دستگاه محاسبه، روش‌هایی برای رفع این مشکلات بوجود آمده‌اند. یکی از این روش‌ها استفاده از یک معماری `programming` به نام MapReduce یا نگاشت/کاهش بود که به کاربران قابلیت پردازش داده‌های با حجم بسیار زیاد را با کمک معماری سیستم‌های توزیع‌شده می‌دهد. قابلیت پردازش موازی، زمان اجرای برنامه با حجم زیاد را به مقدار قابل توجهی کاهش می‌دهد بنابراین مورد توجه مهندسين داده و برنامه‌نویسان است.

از طرفی دیگر، با الگوریتم‌های رتبه‌بندی اینترنت از قبیل PageRank و HITS آشنا می‌شویم که بسیار به رتبه‌بندی صفحات وب کمک کرده‌اند. این روش‌ها در ادامه بسته به نیاز شرکت‌ها تغییر کردند تا از مشکلات امروزی از قبیل Web spamming جلوگیری کنند.

اهداف تمرین:

- استخراج زوج کلمات مرتبط در مجموعه داده با معماری MapReduce
- پیاده‌سازی الگوریتم‌های PageRank و HITS
- مقایسه نتایج بدست آمده و تحلیل نتایج

نکات قابل توجه در هنگام پاسخ به سؤالات:

- فایل قوانین استفاده از ابزارهای مبتنی بر LLMs نظیر ChatGPT که در ایلرن آپلود شده است را به دقت مطالعه کنید.
- توصیه می‌شود انجام تمرین را به روزهای آخر موکول نکنید.
- بدیهی است که حجم تمرین معیار نمره شما نیست، بلکه کیفیت تحلیل و صحت انجام آزمایش‌ها مهم است.

سوالات عملی (۶۰ نمره)

در سوال اول تمرین پیاده سازی یک نگاشت/کاهش (MapReduce) خواهیم داشت و در سوال دوم تمرین پیاده سازی الگوریتم های PageRank و HITS هدف اصلی سوال هستند.

برای پیاده سازی سوال اول کتابخانه MRJob و برای سوال دوم کتابخانه NetworkX توصیه می شوند. توصیه می شود که مستندات این دو کتابخانه را مطالعه کنید. همچنین استفاده از کتابخانه های مرسوم مانند NLTK و Numpy و Pandas و غیره هم مجاز است.

در سوال اول، قبل از پیاده سازی الگوریتم خواسته شده پیش پردازش های لازم بر روی متن مجموعه داده را انجام دهید و بعد از آن به پیاده سازی سوالات خواسته شده بپردازید.

مجموعه داده سوال اول مجموعه‌ای از ۵۰۰۰۰ نقد راجع به فیلم‌های مختلف از سایت IMDB است که از [این لینک](#) در دسترس است که دو ستون نقد و مثبت یا منفی بودن نظر کاربر را دارد. در این مجموعه داده ۲۵۰۰۰ نقد منفی و ۲۵۰۰۰ نقد مثبت راجع به فیلم‌های مربوطه وجود دارد که هدف اصلی تمرین بر روی متن نقد است اما از محتوای برچسب هم در حل مسئله استفاده می‌شود.

مجموعه داده سوال دوم مجموعه نقدی بر غذاهای سرویس آمازون است که از [این لینک](#) قابل دسترسی است. توصیه می‌شود این مجموعه‌داده را از طریق API سایت Kaggle و بر روی بستر Google colab دریافت کنید. بعد از دریافت مجموعه‌داده تمرکز سوال دوم عملی بر روی فایل Reviwes.csv است.

این مجموعه داده شامل بیش از ۵۰۰۰۰۰ نقد و امتیاز بر محصولات است که شامل ستون‌های زیر است:

- ProductId یا شناسه محصول
- UserId یا شناسه کاربر
- HelpfulnessNumerator یا تعداد کاربرانی که این نقد را پسندیده‌اند.
- HelpfulnessDenominator یا تعداد کاربرانی که این نقد را مفید دانسته یا ندانسته‌اند.
- Score یا امتیازی که کاربر به محصول داده است.
- Time یا زمانی که کاربر این نقد را انجام داده است.
- Summary یا خلاصه‌ای از نقد کاربر بر محصول
- Text یا نقد کامل کاربر بر محصول

سوال ۱: پیاده سازی الگوریتم نگاشت/کاهش (۳۰ نمره)

ابتدا پیش پردازش های لازم بر روی ستون review را انجام دهید و سپس به سوالات زیر پاسخ دهید. این پیش پردازش ها می تواند مانند حذف Stop word ها، جدا کردن کلمات از هم دیگر و ریشه یابی است.

الف) تعداد نظرهای مثبت یا منفی را بدست بیاورید و این مجموعه داده را به ۲ مجموعه داده جدا مبتنی بر متن نظر افراز کنید.

ب) ۵۰ کلمه با بیشترین تکرار در نظرات مثبت و منفی را با استفاده از الگوریتم Mapreduce بدست بیاورید و این کلمات با تعداد تکرارشان را در ۲ فایل متنی ذخیره کنید. هنگام ارسال پاسخ تمرین این فایل ها را هم ارسال کنید.

ج) ۵۰ جفت کلمه متوالی با بیشترین تکرار در نظرات مثبت و منفی را با استفاده از همین الگوریتم بدست بیاورید و مانند قسمت قبل در ۲ فایل متنی ذخیره کنید.

د) نتایج را تحلیل کنید. آیا جواب های بدست آمده منطقی هستند؟

سوال ۲: پیاده‌سازی الگوریتم PAGERANK و HITS (۳۰ نمره)

الف) مجموعه داده مرتبط با سوال دوم را در نظر بگیرید. ستون‌های اضافی را در نظر بگیرید و فقط ۳ ستون نام کاربر، شناسه محصول و امتیاز در نظر بگیرید. گرافی مبتنی بر این مجموعه داده بسازید که گره‌ها محصولات و کاربران باشند و ارتباط بین این گره‌ها با نقد کاربر بر محصول برقرار می‌شود (منظور این است که یالی بین دو گره محصول و کاربر وجود دارد اگر کاربر برای آن محصول نقدی ثبت کرده باشد). این گراف چه خاصیتی باید داشته باشد؟ گراف خود را وزن‌دار و وزن آن را امتیاز داده شده به هر محصول در نظر بگیرید.

ب) الگوریتم HITS را بر روی گراف خود با تعداد تکرار ۱۰ پیاده‌سازی کنید. باید دو بردار Authority و Hub را به دست بیاورید. با توجه به تعریف اولیه شکل‌گیری گراف مورد نظر، آیا این دو بردار نیازمند تغییر هستند؟ اگر نیازمند تغییر هستند دلیل خود را بیان کنید و بردارهای نهایی خود را بازگردانید.

ج) آیا بین بردارهای به دست آمده در قسمت ب و میزان تکرار محصولات و کاربران در مجموعه داده، ارتباطی وجود دارد؟ ابتدا با توجه به تعریف الگوریتم HITS حدس خود را بنویسید و سپس این ارتباط را در کد خود تحلیل کنید.

ج) الگوریتم PageRank را با تعداد تکرار ۱۰ پیاده‌سازی کنید. ۱۰ محصول با بیش‌ترین امتیاز را بازگردانید.

د) کاربری با تعداد نقد بیش‌از ۱۰ در نظر بگیرید. (ترجیحا تعداد نقدهای زیادی داشته باشد). مجدداً الگوریتم Topic sensitive PageRank مختص به این کاربر را اجرا کنید و ۱۰ محصول برتر را به کاربر برگردانید. امتیازاتی که این کاربر به این ۱۰ محصول داده است را بررسی کنید و جواب را تحلیل کنید.

سوالات تئوری (۴۰ نمره)

با توجه به مباحث تدریس شده در کلاس به سوالات زیر پاسخ دهید. پاسخ این سوالات را باید در قالب مربوط به سوالات تئوری (IIR-CA3-Theory) بنویسید.


نکات سوالات تئوری:

- صرفاً به جواب نهایی نمره تعلق نمی‌گیرد و راه‌حل نوشته شده بخش اصلی نمره شماست.
- می‌توانید جهت امتحان از محاسبات خود از کدنویسی استفاده کنید، اما باید راه‌حل را به صورت کامل و با عبارات ریاضی در گزارش تمرین یادداشت کنید.

سوال ۱: محاسبات PAGERANK (۲۵ نمره)

الف) دو مشکل dead ends و spider traps در الگوریتم PageRank را توضیح داده و برای هر دو مشکل مثالی بزنید که نشان دهد چرا این الگوریتم بدون Random surfing برای گراف‌هایی با این مشکل جواب نمی‌دهد؟ (گراف‌ها را رسم کنید و جواب‌های نهایی را هم یادداشت کنید. لازم نیست گراف پیچیده‌ای در نظر بگیرید و ساده‌ترین گراف‌ها با این مشکلات هم قابل قبول است).

ب) شبکه ساده زیر را در نظر بگیرید.



امتیاز هر کدام از گره‌ها را با الگوریتم PageRank محاسبه کنید. در این حالت α را برابر با ۰ در نظر بگیرید.

ج) این بار α را برابر با ۰/۱ در نظر بگیرید. بعد از ۲ بار تکرار، امتیاز گره‌ها را به دست بیاورید.

سوال ۲: نگاشت/کاهش (۱۵ نمره)

الف) آیا عملیات ضرب ماتریسی را می‌توان با پیاده‌سازی Mapreduce انجام داد؟ راجع به این موضوع توضیح دهید. ماتریس را مربعی فرض کنید.

ب) آیا می‌توان از معماری Mapreduce در الگوریتم HITS استفاده کرد؟ در این رابطه فکر کنید و تحلیل خود را شرح دهید.

دیتاست سوال دوم عملی را در نظر بگیرید (سوال پیاده‌سازی الگوریتم PageRank و HITS)، به سوالات زیر پاسخ دهید.

ج) شبه‌کدی مبتنی بر معماری MapReduce برای بدست آوردن ۱۰ محصول برتر با بیش‌ترین میانگین امتیاز را بنویسید.

د) شبه‌کدی مبتنی بر بازگرداندن ۱۰ زوج-کلمه با بیش‌ترین تکرار در نظرات متناظر با امتیاز برابر ۱ بنویسید.

ملاحظات (حتما مطالعه شود)

تمامی نتایج شما باید در یک فایل فشرده با عنوان IIR-CAX-Student3 تحویل داده شود.

- خوانایی و دقت بررسی‌ها در گزارش نهایی از اهمیت ویژه‌ای برخوردار است. به تمرین‌هایی که به صورت کاغذی تحویل داده شوند یا به صورت عکس در سایت بارگذاری شوند، ترتیب اثری داده نخواهد شد. **دقت کنید که حتما گزارشات خود را در قالب ارائه شده برای تحویل تکالیف که در سامانه برای شما بارگذاری شده است ارسال بفرمایید.**
- کدهای نوشته شده برای هر بخش را با نام مناسب مشخص کرده و به همراه گزارش تکلیف ارسال کنید. همه‌ی کدهای پیوست گزارش بایستی قابلیت اجرای مجدد داشته باشند. در صورتی که برای اجرا مجدد آن‌ها نیاز به تنظیمات خاصی می‌باشد بایستی تنظیمات مورد نیاز را نیز در گزارش خود ذکر کنید. **دقت کنید که تمامی کدها باید توسط شما اجرا شده باشند و نتایج اجرا در فایل کدهای ارسالی مشخص باشد. به کدهایی که نتایج اجرای آن‌ها در فایل ارسالی مشخص نباشد نمره‌ای تعلق نمی‌گیرد.**
- تمرین تا یک هفته بعد از مهلت تعیین شده با تأخیر تحویل گرفته می‌شود. دقت کنید که شما جمعا برای تمام تکالیف، ۱۴ روز زمان تحویل بدون جریمه دارید که تنها از ۷ روز آن برای هر تمرین می‌توانید استفاده کنید، در صورتی که این ۱۴ روز به اتمام رسیده باشد، به ازای هر روز تأخیر در ارسال تمرین، ده درصد جریمه می‌شود.
- **توجه کنید این تمرین باید به صورت تک نفره انجام شود و پاسخ‌های ارائه شده باید نتیجه فعالیت فرد نویسنده باشد (همفکری و به اتفاق هم نوشتن تمرین نیز ممنوع است).** در صورت مشاهده تشابه به همه افراد مشارکت کننده، نمره ۵۰- تعلق می‌گیرد و به استاد نیز گزارش می‌گردد.
- در صورت بروز هرگونه مشکل با ایمیل زیر در ارتباط باشید:

adibialii@ut.ac.ir

تاریخ آپلود تمرین	۱۵ آبان ۱۴۰۳
مهلت تحویل بدون جریمه	۲۷ آبان ۱۴۰۳
مهلت تحویل با تأخیر، با جریمه ۱۰ درصد	۴ آذر ۱۴۰۳