

به نام خدا



دانشگاه تهران
دانشکده فنی
دانشکده مهندسی برق و
کامپیوتر



درس بازیابی هوشمند اطلاعات

پاسخ بخش تئوری تمرین ۴

نام و نام خانودگی: عرفان شهابی

آبان ماه ۱۴۰۳

پاسخ سوال دوم 3

پاسخ بخش ۱ 3

پاسخ بخش ۲ 4

پاسخ بخش ۳ 6

پاسخ سوال دوم

پاسخ بخش ۱

سند شبه متن برای کشف روابط جانشینی مفید است زیرا کلمات با زمینه‌های مشابه را شبیه سازی می‌کند. کلماتی که در متون مشابه یا در کنار هم به طور مکرر ظاهر می‌شوند، معمولاً معانی مشابه دارند و می‌توانند به عنوان کلمات جانشین شناخته شوند. این فرآیند با تحلیل هم‌نشینی کلمات و مدل‌های یادگیری ماشین انجام می‌شود. کلمات با زمینه‌های مشابه معمولاً به عنوان کلمات جانشین در نظر گرفته می‌شوند زیرا آنها در متن‌ها یا اسناد مختلف به طور مشابه یا در کنار هم استفاده می‌شوند.

پاسخ بخش ۲

برای پیش بینی اینکه واژگانی مانند plot یا ending در جملاتی که کلمه bad در آن ظاهر شده است، با استفاده

از Mutual Information (MI)، بدین صورت است که:

محاسبه Mutual Information (MI) :

- MI معیاری است برای اندازه‌گیری میزان وابستگی میان دو کلمه در یک متن.

- فرمول MI برای دو کلمه x و y به این صورت است:

$$MI(x, y) = \log\left(\frac{p(x, y)}{p(x)p(y)}\right)$$

برای پیش بینی اینکه آیا plot یا ending در جمله ای که bad وجود دارد، ظاهر می شوند یا نه، ابتدا باید MI بین

bad و هر یک از این کلمات را محاسبه کنیم. اگر MI بین bad و plot یا ending زیاد باشد، به این معنی است

که این کلمات در کنار هم در جملات مشابه ظاهر می شوند و احتمال اینکه این کلمات در جمله ای که bad دارد،

ظاهر شوند بیشتر است.

تأثیر کاهش عدم قطعیت (Conditional Entropy) :

- Conditional Entropy به میزان عدم قطعیت باقی مانده پس از مشاهده کلمه bad اشاره دارد.

- فرمول Conditional Entropy به شکل زیر است:

$$H(X|y) = -\sum p(y|x) \log(p(y|x))$$

که در آن:

- $P(y|x)$ احتمال وقوع y (مثل plot یا ending) زمانی است که x مثل bad قبلاً مشاهده شده باشد.

- کاهش عدم قطعیت (کاهش در $H(X|Y)$) به این معنی است که پیش بینی بهتر و دقیق‌تری می‌توان

برای حضور کلمات دیگر انجام داد.

وقتی که MI بالا باشد، به این معنی است که کاهش عدم قطعیت (Conditional Entropy) بیشتر است و مدل می‌تواند پیش‌بینی بهتری از کلمات مرتبط با bad مانند plot یا ending داشته باشد. در نتیجه، دقت پیش‌بینی افزایش می‌یابد، زیرا احتمال وقوع کلمات خاص در کنار bad به‌طور قابل‌ملاحظه‌ای بیشتر می‌شود.

پاسخ بخش ۳

روابط جانشینی و هم‌نشینی به سیستم‌های بازبازی اطلاعات کمک می‌کنند تا درک بهتری از معنای متن و ارتباط میان کلمات داشته باشند. این دو رابطه می‌توانند عملکرد سیستم را در بازبازی نتایج مرتبط و دقیق‌تر بهبود بخشند. سیستم از روابط بین کلمات در متن استفاده می‌کند که به‌طور طبیعی در کنار یک دیگر ظاهر می‌شوند. این روابط به شناسایی ساختارهای زبانی کمک می‌کند. سیستم از کلماتی که می‌توانند به جای یک دیگر استفاده شوند (مانند مترادف‌ها یا کلمات با معنای مشابه) بهره می‌برد. این روابط به گسترش دامنه جستجو کمک می‌کنند.

سناریو:

فرض کنید یک کاربر به دنبال اطلاعات درباره مشکلات تغییرات آب و هوایی است و عبارت climate change challenges را جستجو می‌کند.

استفاده از روابط هم‌نشین (Syntagmatic) :

سیستم جملاتی را شناسایی می‌کند که در آن‌ها کلمات climate و change در کنار کلماتی مانند challenges، problems، issues ظاهر می‌شوند. این رابطه به سیستم کمک می‌کند تا نتایجی را پیدا کند که دقیقاً به زمینه تغییرات آب و هوایی مرتبط هستند.

استفاده از روابط جانشینی (Paradigmatic) :

سیستم کلمات جایگزین یا مترادف را شناسایی می‌کند. برای مثال:

- به‌جای climate change ، از عبارت‌هایی مانند global warming یا environmental changes

استفاده می‌کند.

- به‌جای challenges، کلمات risks، issues یا impacts را نیز جستجو می‌کند.

نتیجه:

سیستم با استفاده از هر دو نوع رابطه، نتایج جامع تر و مرتبط تری را ارائه می دهد. حتی اگر کاربر دقیقاً از واژه های موجود در اسناد استفاده نکرده باشد، سیستم قادر است اطلاعات مرتبط را بازیابی کند.