

به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر



درس بازیابی هوشمند اطلاعات تمرین ۴

استاد درس: خانم دکتر آزاده شاکری

سرپرست دستیاران آموزشی: سمانه پیمانی‌راد

طراح تمرین: هومن شیروانی

آبان ماه ۱۴۰۳

۳	مقدمه
۵	IMDb Movie Reviews مجموعه داده سوال
۶	سوال اول (۴۰ نمره)
۹	سوال دوم (نظری) (۱۵ نمره)
۱۰	OHSUMED مجموعه داده
۱۲	سوال سوم (۵۵ نمره)
۱۵	ملاحظات (حتما مطالعه شود)

موضوع تمرین:

در این تمرین، شما با یکی از کاربردهای کلیدی پردازش زبان طبیعی (NLP) به نام تحلیل احساسات (Sentiment Analysis) آشنا می‌شوید. تحلیل احساسات، فرآیندی است که در آن مدل‌های یادگیری ماشین تلاش می‌کنند احساسات یا نظر کلی نویسنده یک متن را شناسایی کنند. در این پروژه، تمرکز ما بر پیش‌بینی احساسات (مثبت یا منفی) نقدهای فیلم از مجموعه داده‌های IMDb Movie Reviews است. در ادامه با استفاده از داده‌های مذکور مفاهیمی نظیر روابط جانشینی و روابط هم‌نشینی مورد بررسی قرار خواهد گرفت. در بخش بعدی تمرین، تمرکز بر یادگیری رتبه‌بندی است که با استفاده از مجموعه داده OHSUMED پیاده‌سازی و ارزیابی می‌شود. یادگیری رتبه‌بندی به عنوان یکی از موضوعات مهم یادگیری ماشین، نقش اساسی در بهبود کارایی سیستم‌های جستجو دارد و این بخش از تمرین به آشنایی با این تکنیک‌ها اختصاص یافته است.

اهداف تمرین:

- پیاده‌سازی مدل‌های مختلف LTR: ساخت مدل‌هایی بر اساس روش‌های Pairwise ، Pointwise و Listwise برای یادگیری رتبه‌بندی.
- ارزیابی مدل‌ها با معیارهای مختلف: مقایسه مدل‌ها بر اساس معیارهایی مختلف
- تحلیل عملکرد و تفاوت‌های مدل‌ها: درک مزایا و معایب هر روش و تحلیل عمیق‌تر برای تشخیص اینکه کدام روش برای رتبه‌بندی اسناد پزشکی مناسب‌تر است.
- طراحی و آموزش مدل Naive Bayes.
- آشنایی با روابط واژگانی (جانشینی و هم‌نشینی) و اهمیت آن‌ها.
- تحلیل داده‌های واقعی برای کشف ارتباطات معنایی میان واژگان.

نکات قابل توجه در هنگام پاسخ به سؤالات:

- تمامی کدهای نوشته شده باید قابلیت اجرای مجدد داشته باشند. به تفسیرهایی که بدون آزمایش و صرفاً به صورت فرضی بیانگردند نمرهای تعلق نمیگیرد.
- نمره اصلی تمرین مربوط به کیفیت و درستی تفسیرهای ارائه شدهاست.
- بدیهی است که حجم تمرین معیار نمره‌ی شما نیست، بلکه صحت انجام آزمایش‌ها و کیفیت تفسیرهای شما مهم است.
- توصیه میشود انجام تمرین را به روزهای آخر مוקول نکنید! اجرای آزمایشها زمانبر بوده و تفسیر هرکدام نیازمند تحلیل و بررسی است.
- فایل قوانین استفاده از ابزارهای مبتنی بر LLMs نظیر ChatGPT که در ایلرن آپلود شدهاست را به دقت مطالعه کنید.

مجموعه داده سوال IMDB MOVIE REVIEWS

مجموعه داده IMDb Movie Reviews یکی از مجموعه داده‌های استاندارد برای انجام تمرینات و

پژوهش‌ها در حوزه تحلیل احساسات (Sentiment Analysis) است.

موضوع دیتاست:

شامل بررسی‌ها و نظرات کاربران درباره فیلم‌ها است که از پایگاه داده IMDb جمع‌آوری شده است.

هدف اصلی از این دیتاست، پیش‌بینی احساسات کاربران بر اساس متون بررسی‌ها است.

داده‌های موجود:

هر نمونه متن همراه با یک برچسب احساس (Sentiment Label) است:

مثبت (۱) : اگر کاربر نظر مثبتی درباره فیلم داده باشد.

منفی (۰) : اگر کاربر منفی باشد.

سوال اول (۴۰ نمره)

این تمرین شامل تحلیل احساسات نقدهای فیلم با استفاده از مدل‌های پیش‌آموزش داده‌شده Word2Vec و GloVe و مقایسه عملکرد آن‌ها در مدل ساده Naive Bayes است.

بخش ۱: آماده‌سازی داده‌ها

- داده‌های **IMDb Movie Reviews** را از [لینک رسمی](#) دانلود کنید. نقدهای مثبت در train/pos و نقدهای منفی در train/neg قرار دارند، نقدهای موجود در پوشه test/pos و test/neg را مشابه داده‌های آموزشی بارگذاری و پیش‌پردازش کنید.

- نقدهای مثبت و منفی را از داده‌های IMDb Movie Reviews بارگذاری کنید.

- متن‌ها را پیش‌پردازش کنید:

- حذف علائم نگارشی.

- کوچک‌سازی حروف.

- حذف توقف‌واژه‌ها (Stopwords).

الف) تعداد نقدهای مثبت و منفی در مجموعه داده را محاسبه کرده و نسبت آن‌ها را گزارش دهید.

ب) بعد از پیش‌پردازش، ۵ نقد اول را نمایش دهید. توضیح دهید چه تغییراتی در متن‌ها اعمال شده است.

بخش ۲: استخراج ویژگی‌ها با Word2Vec و GloVe

- از مدل‌های پیش‌آموزش داده‌شده زیر برای استخراج بردارهای معنایی استفاده کنید:

- Word2Vec

- GloVe

الف) برای هر نقد، بردار میانگین کلمات موجود در آن نقد را محاسبه کنید.

بخش ۳: آموزش مدل Naive Bayes

- از بردارهای معنایی استخراج شده Word2Vec و GloVe برای آموزش مدل Naive Bayes استفاده کنید.

الف) دقت (Accuracy) و F1-Score مدل برای Word2Vec و GloVe را محاسبه و گزارش کنید.

ب) کدام مدل عملکرد بهتری داشته است؟ توضیح دهید چرا.

بخش ۴: تحلیل خطاها

- نقدهایی که مدل به اشتباه پیش‌بینی کرده است، بررسی کنید.
- کلمات یا عباراتی که مدل را گمراه کرده‌اند شناسایی کنید.

الف) یکی از نقدهایی که مدل به اشتباه پیش‌بینی کرده است، انتخاب کنید و توضیح دهید چرا مدل خطا کرده است.

ب) آیا کلمات خاصی در نقد باعث گمراهی مدل شده‌اند؟ اگر بله مثال بزنید.

بخش ۵: تحلیل روابط جانشینی (Paradigmatic Relations)

تحلیل شباهت معنایی با استفاده از سند شبه‌متن (Pseudo Document)

۱. کلمه movie را به عنوان کلمه هدف انتخاب کنید.

۲. برای تشکیل سند شبه‌متن:

- در هر نقد، کلماتی که در پنجره ۵ کلمه‌ای سمت چپ و راست movie قرار دارند را استخراج کنید.

○ برای هر بار وقوع movie در نقدها، کلمات زمینه‌ای آن را به سند شبه‌متن اضافه کنید.
۳. پس از تشکیل سند شبه‌متن:

○ کلمات پرتکرار در این سند مانند character, story, film را به صورت خودکار استخراج کنید.

۴. شباهت معنایی بین کلمه movie و این کلمات پرتکرار را با استفاده از فراوانی مشترک و Similarity Cosine محاسبه کنید.

الف) کدام کلمه بیشترین شباهت معنایی به movie دارد؟
ب) آیا نتایج محاسبه شده با موضوع نقدها همخوانی دارند؟ توضیح دهید.

بخش ۶: تحلیل روابط هم‌نشینی (Syntagmatic Relations)

تحلیل هم‌نشینی با استفاده از اطلاعات متقابل (Mutual Information)

۱. کلمه movie را به عنوان کلمه هدف انتخاب کنید.

۲. برای کلمات پرتکرار هم‌نشین:

○ بررسی کنید کدام کلمات اغلب در کنار movie ظاهر می‌شوند و تعداد دفعات هم‌نشینی آن‌ها را بشمارید.

۳. برای دو کلمه movie و story:

○ احتمال وقوع هر کلمه $P(\text{movie})$ و $P(\text{story})$ و احتمال وقوع مشترک آن‌ها

$(P(\text{movie}, \text{story}))$ را محاسبه کنید.

۴. نتایج MI را تفسیر کنید:

الف) آیا اطلاعات متقابل بالا نشان‌دهنده وابستگی معنایی قوی بین این دو کلمه است؟
ب) کدام کلمات بیشتر در نقدهای مثبت ظاهر می‌شوند و کدام در منفی؟

سوال دوم (نظری) (۱۵ نمره)

۱. چرا سند شبه‌متن (**Pseudo Document**) برای کشف روابط جانشینی مناسب است؟

○ توضیح دهید چگونه کلمات با زمینه‌های مشابه می‌توانند به‌عنوان کلمات جانشین شناخته شوند.

۲. با فرض داده‌های IMDb، اگر کلمه "bad" در جمله‌ای ظاهر شود، چگونه می‌توان با استفاده از

Mutual Information (MI) پیش‌بینی کرد که واژگان دیگری مانند "plot" یا "ending" نیز در

همان متن ظاهر می‌شوند؟ چه تأثیری کاهش عدم قطعیت (**Conditional Entropy**) بر دقت این پیش‌بینی دارد؟

۳. چگونه روابط جانشینی و هم‌نشینی می‌توانند در سیستم‌های بازیابی اطلاعات استفاده شوند؟

○ یک سناریو را توضیح دهید که در آن استفاده از این روابط باعث بهبود عملکرد سیستم شود.

OHSUMED یک مجموعه داده معتبر و مشهور در زمینه یادگیری رتبه‌بندی (LTR) است که به‌ویژه برای پژوهش‌های پزشکی و اطلاعات پزشکی مورد استفاده قرار می‌گیرد. این مجموعه، زیرمجموعه‌ای از بانک اطلاعاتی بزرگ MEDLINE است که شامل مقالات پژوهشی و مطالعات علمی مرتبط با پزشکی و سلامت می‌شود.

مجموعه داده OHSUMED شامل پرس‌وجوهای جستجوی پزشکی به همراه اسناد مرتبط است و این داده‌ها به صورت برچسب‌گذاری شده (یعنی مرتبط یا غیرمرتبط) با هر پرس‌وجو ارائه می‌شوند. هر رکورد شامل شناسه پرسش، یک امتیاز مرتبط بودن و چندین ویژگی عددی است که اطلاعات مختلفی در مورد سند و پرس‌وجو ارائه می‌دهد. این ساختار به پژوهشگران امکان می‌دهد تا مدل‌های یادگیری رتبه‌بندی را برای بهینه‌سازی جستجو و رتبه‌بندی نتایج جستجو بر اساس ارتباط سند با پرس‌وجو استفاده کنند.

در این مجموعه داده هر خط داده شامل برچسب ارتباط، شناسه کوئری، ۴۵ ویژگی عددی برای هر سند و شناسه سند است. این ساختار استاندارد مجموعه داده‌های Learning to Rank است.

هر سطر این مجموعه داده اطلاعات زیر را در بر می‌گیرد:

۱. <relevance>

○ این فیلد نشان‌دهنده درجه ارتباط (relevance) سند با کوئری است.

○ مقادیر ممکن: ۰، ۱، ۲ (به ترتیب کم، متوسط و زیاد)

۲. <queryid:qid>

○ این فیلد شناسه منحصر به فرد کوئری را مشخص می‌کند.

○ queryid یک مقدار عددی است.

۳. <feature۴۵>, ..., <feature۲>, <feature۱>

- این فیلدها ویژگی‌های استخراج‌شده برای هر سند را نشان می‌دهند.
- در مجموع ۴۵ ویژگی برای هر سند در نظر گرفته شده است.
- هر ویژگی با یک شماره مشخص می‌شود (۱ تا ۴۵)
- مقادیر این ویژگی‌ها عددی هستند.

۴. #docid

- این فیلد شناسه منحصر به فرد هر سند را مشخص می‌کند.

سوال سوم (۵۵ نمره)

۱. آماده‌سازی مجموعه داده

الف) تقسیم داده‌ها:

- شناسه‌های پرس‌وجو (qid) را استخراج کرده و آن‌ها را به دو مجموعه آموزشی و تست تقسیم کنید.
- تمامی اسناد مرتبط با یک پرس‌وجو باید در یک مجموعه قرار گیرند (آموزشی یا تست) تا از نشت داده جلوگیری شود.
- نسبت پیشنهادی تقسیم: ۸۰٪ آموزشی و ۲۰٪ تست.

ب) بررسی تعادل توزیع: relevance

- اطمینان حاصل کنید که توزیع نمرات مرتبط بودن در هر دو مجموعه مشابه باشد.
- این کار را با بررسی مقادیر relevance در مجموعه‌های آموزشی و تست انجام دهید.

ج) نرمال‌سازی ویژگی‌ها:

- ویژگی‌های عددی ($feature_1, feature_2, \dots$) را به بازه ۰ تا ۱ نرمال‌سازی کنید

۲. پیاده‌سازی روش‌های LTR

الف) روش Pointwise (رگرسیون):

با استفاده از یک مدل رگرسیون (مانند رگرسیون خطی یا درخت تصمیم)، مدلی پیاده‌سازی کنید که امتیاز مرتبط بودن هر سند را پیش‌بینی کند.

از معیار Mean Squared Error (MSE) برای ارزیابی مدل استفاده کنید.

ب) روش: Pairwise (Ranking SVM)

با استفاده از Ranking SVM داده‌ها را به جفت اسناد تقسیم کنید تا مدل بتواند ترجیحات جفت‌ها را بیاموزد.

در این روش، مدلی پیاده‌سازی کنید که برای هر جفت سند، رتبه مرتبط‌تر را تشخیص دهد.

ج) روش: Listwise (LambdaMART)

با استفاده از XGBoost یا LambdaMART، مدلی پیاده‌سازی کنید که به جای یادگیری امتیاز یا جفت‌ها، کل لیست اسناد مرتبط با هر پرسش را بهینه کند.

از معیارهای رتبه‌بندی مانند $NDCG@10$ و MAP برای ارزیابی استفاده کنید.

۳. ارزیابی و مقایسه مدل‌ها

الف) ارزیابی مدل‌ها: مدل‌ها را بر اساس معیارهای $NDCG@10$ ، MAP و $Precision@10$ ارزیابی کنید.

ب) تحلیل عملکرد: تحلیل کنید که کدام روش برای داده‌های OHSUMED و نوع پرسش‌ها عملکرد بهتری دارد.

۴. تحلیل چالش‌های هر روش

الف) نقاط ضعف و قوت: نقاط ضعف و قوت هر روش Pointwise، Pairwise و Listwise را بررسی کنید.

ب) تحلیل دقت روش‌ها: توضیح دهید چرا روش‌های Pairwise و Listwise ممکن است دقت بهتری داشته باشند.

(راهنمایی: برای انجام این بخش از تمرین می‌توانید از کتابخانه‌های Scikit-learn و XGBoost و یا LightGBM استفاده کنید.)

ملاحظات (حتما مطالعه شود)

- تمامی نتایج شما باید در یک فایل فشرده با عنوان IIR-CA4-StudentID تحویل داده شود.
- خوانایی و دقت بررسی‌ها در گزارش نهایی از اهمیت ویژه‌ای برخوردار است. به تمرین‌هایی که به صورت کاغذی تحویل داده شوند یا به صورت عکس در سایت بارگذاری شوند، ترتیب اثری داده نخواهد شد. **دقت کنید که حتما گزارشات خود را در قالب ارائه شده برای تحویل تکالیف که در سامانه برای شما بارگذاری شده است ارسال بفرمایید.**
- کدهای نوشته شده برای هر بخش را با نام مناسب مشخص کرده و به همراه گزارش تکلیف ارسال کنید. همه‌ی کدهای پیوست گزارش بایستی قابلیت اجرای مجدد داشته باشند. در صورتی که برای اجرا مجدد آن‌ها نیاز به تنظیمات خاصی می‌باشد بایستی تنظیمات مورد نیاز را نیز در گزارش خود ذکر کنید. **دقت کنید که تمامی کدها باید توسط شما اجرا شده باشند و نتایج اجرا در فایل کدهای ارسالی مشخص باشد. به کدهایی که نتایج اجرای آن‌ها در فایل ارسالی مشخص نباشد نمره‌ای تعلق نمی‌گیرد.**
- تمرین تا یک هفته بعد از مهلت تعیین شده با تأخیر تحویل گرفته می‌شود. دقت کنید که شما جمعا برای تمام تکالیف، ۱۴ روز زمان تحویل بدون جریمه دارید که تنها از ۷ روز آن برای هر تمرین می‌توانید استفاده کنید، در صورتی که این ۱۴ روز به اتمام رسیده باشد، به ازای هر روز تأخیر در ارسال تمرین، ده درصد جریمه می‌شوید.
- توجه کنید این تمرین باید به صورت تک نفره انجام شود و پاسخ‌های ارائه شده باید نتیجه فعالیت فرد نویسنده باشد (همفکری و به اتفاق هم نوشتن تمرین نیز ممنوع است). در صورت مشاهده تشابه به همه افراد مشارکت کننده، نمره ۵۰- تعلق می‌گیرد و به استاد نیز گزارش می‌گردد.
- در صورت بروز هرگونه مشکل با ایمیل زیر در ارتباط باشید:

Hoomanshirvani@ut.ac.ir

تاریخ آپلود تمرین	۳۰ آبان ۱۴۰۳
مهلت تحویل بدون جریمه	۱۲ آذر ۱۴۰۳
مهلت تحویل با تأخیر، با جریمه ۱۰ درصد	۱۹ آذر ۱۴۰۳